

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Anh Khôi - 22127208

**MỘT KHUNG ĐA NHIỆM CHO PHÁT
HIỆN BẤT THƯỜNG CHUỖI THỜI
GIAN VỚI BẤT ĐỊNH NGẪU NHIÊN**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIẢNG VIÊN HƯỚNG DẪN

GS.TS. Lê Hoài Bắc

PGS.TS. Kiều Vũ Thanh Tùng

Tp. Hồ Chí Minh, tháng 08/2026

Lời cam đoan

Tôi xin cam đoan khoá luận tốt nghiệp cử nhân ngành Công nghệ thông tin, với đề tài “Một khung đa nhiệm cho phát hiện bất thường chuỗi thời gian với bất định ngẫu nhiên” là công trình nghiên cứu của tôi dưới sự hướng dẫn của GS. TS. Lê Hoài Bắc và PGS. TS. Kiều Vũ Thanh Tùng.

Những kết quả nghiên cứu của khoá luận là hoàn toàn trung thực và không trùng lặp với các công trình nghiên cứu đã được công bố trong nước và ngoài nước.

Lời cảm ơn

Em xin chân thành cảm ơn Khoa Công nghệ thông tin Trường Đại học khoa học Tự nhiên - ĐHQG-HCM vì đã luôn tạo điều kiện tốt để sinh viên có cơ hội thực hành kỹ năng nghiên cứu thông qua học phần khoá luận tốt nghiệp. Em xin gửi lời cảm ơn chân thành đến GS. TS. Lê Hoài Bắc vì thầy đã tạo điều kiện để em được lựa chọn và theo đuổi đề tài này, dù đây là một đề tài thử thách. Em xin cảm ơn PGS. TS. Kiều Vũ Thanh Tùng vì tất cả những gì thầy đã hướng dẫn và gợi mở trong suốt quá trình thực hiện khoá luận. Những hướng dẫn, gợi mở, động viên và khả năng phản biện của thầy đã giúp em được trải nghiệm một môi trường nghiên cứu thật sự khó quên, thúc đẩy em tìm đọc và suy nghĩ vượt ra khỏi rất nhiều giới hạn. Và cuối cùng, con cảm ơn gia đình vì đã luôn ở bên.



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

Một khung đa nhiệm cho phát hiện bất thường chuỗi thời gian với bất định ngẫu nhiên

A Robust Multi-Task Framework for Time Series Anomaly Detection with Stochastic Uncertainty

0.1 THÔNG TIN CHUNG

Người hướng dẫn:

- GS. TS. Lê Hoài Bắc (Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia TP. HCM)
- PGS. TS. Kiều Vũ Thanh Tùng (Department of Computer Science, Aalborg University)

Sinh viên thực hiện:

1. Nguyễn Anh Khôi (MSSV: 22127208)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 01/2026 đến 07/2026

0.2 NỘI DUNG THỰC HIỆN

0.2.1 Giới thiệu về đề tài

Phát hiện bất thường chuỗi thời gian (TSAD - Time Series Anomaly Detection) là một bài toán quan trọng có nhiều ứng dụng trong đa dạng các lĩnh vực như trong các khoa hồi sức tích cực (ICUs – Intensive Care Units) [1], trong các hệ thống đám mây và hệ thống phân tán [2], trong bài toán giám sát người bệnh tại nhà [3], và nhiều ứng dụng khác. Các phương pháp TSAD thường dựa trên hai *tác vụ học (learning task)* chính là *dự báo (forecasting)* và *tái tạo chuỗi (reconstruction)*. Trong đó, các phương pháp TSAD *dựa trên tác vụ tái tạo chuỗi (reconstruction-based)* thường được sử dụng để phát hiện bất thường trong các lĩnh vực cần độ chính xác cao, do mô hình trong các phương pháp này dự đoán dựa trên dữ liệu mới nhất, không giống như các phương pháp dựa trên *tác vụ dự báo (forecasting-based)* thường dựa trên dữ liệu lịch sử để dự đoán dữ liệu mới nhất [4]. Trong đề tài này, chúng tôi sẽ nghiên cứu và thảo luận về các phương pháp TSAD dựa trên tác vụ tái tạo chuỗi. Trong các đoạn kế tiếp, chúng tôi sẽ thảo luận về khía cạnh dữ liệu của bài toán TSAD.

Dữ liệu chuỗi thời gian được gán nhãn bất thường, tính đến hiện nay, là tương đối ít, do việc gán nhãn là rất tốn nhân công. Ngoài ra, dữ liệu được xem là bình thường cũng không tránh khỏi nguy cơ bị *nhiễm bất thường (anomaly contamination)*. Vì hai lý do trên, một số phương pháp hiện nay sử dụng các kỹ thuật *gia tăng dữ liệu (data augmentation)* nhằm thu được các *bất thường nhân tạo (pseudo-anomaly)* [5] [6] [7]. Điều này, một mặt giúp các mô hình có nhiều dữ liệu hơn để học được các *mẫu hình bất thường (anomalous pattern)* một cách tiện lợi hơn, mặt khác có thể vô tình tạo ra các bất thường nhân tạo trùng với các bất thường bị nhiễm trong dữ liệu bình thường, giúp mô hình tách biệt được tốt hơn những mẫu hình thật sự bình thường ra khỏi những mẫu hình

bất thường.

Các phương pháp gia tăng dữ liệu bất thường hiện nay dựa trên một trong hai giả định chính: *giả định nhị phân về bất thường (binary anomaly assumption)*, nghĩa là có một lớp bình thường và một lớp bất thường, và *giả định đa lớp về bất thường (multi-class anomaly assumption)*, nghĩa là có một lớp bình thường và nhiều lớp bất thường. Hai *tác vụ học (learning task)* tương ứng với hai giả định này là *phân loại nhị phân (binary classification)* và *phân loại đa lớp (multi-class classification)*.

Các phương pháp học sâu được đề xuất gần đây, bao gồm các phương pháp sử dụng kỹ thuật gia tăng dữ liệu, đã cho thấy kết quả khả quan trong tác vụ phát hiện bất thường chuỗi thời gian. Tuy nhiên, chỉ có số ít phương pháp định lượng được *độ bất định của mô hình (epistemic uncertainty)* [3]. Những phương pháp không định lượng được độ bất định của mô hình không phát hiện được khi nào mô hình đang *quá tự tin (overconfident)*, và khi nào mô hình đang *không chắc chắn (uncertain)*, đặc biệt khi sử dụng mô hình trên dòng dữ liệu thời gian sinh ra từ phân phối khác với phân phối của tập huấn luyện. Điều này làm giới hạn khả năng ứng dụng các phương pháp này trong các lĩnh vực rủi ro cao như y tế kỹ thuật cao, tài chính, và ngân hàng.

Tóm lại, các phương pháp hiện nay có hai hạn chế chung như sau:

- (1) Chưa lượng hoá được *độ bất định (uncertainty)* trong kết quả phân lớp hay trong kết quả phát hiện bất thường.
- (2) Chưa thích ứng được mô hình một cách liên tục (continual adaptation) và hiệu quả (efficiency) trên các dòng dữ liệu thời gian có tính không dừng (non-stationary streaming time series).

Để giải quyết hai vấn đề trên, trong đề tài này, chúng tôi sẽ đề xuất một phương pháp để định lượng độ bất định của mô hình đối với *biểu diễn sâu (deep representation)* mà mô hình học được, bằng cách sử dụng phân phối xác suất trong cơ chế *truy vấn nguyên mẫu (querying prototypes)*. Đồng thời, chúng tôi cũng đề xuất một phương pháp để thích ứng mô hình trên dòng dữ liệu thời gian có tính không dừng, với mục tiêu là đưa

phân phối của biểu diễn sâu tại thời điểm mới về gần với phân phối của biểu diễn sâu mà mô hình học được sau khi trải qua quá trình tiền huấn luyện (pre-training). Ngoài ra, chúng tôi cũng sẽ đề xuất một phương pháp cải tiến biểu diễn mà mô hình học được sao cho mỗi tác vụ trong khung huấn luyện đa tác vụ (multi-task learning) mà chúng tôi sử dụng sẽ có biểu diễn chuyên biệt tương ứng, dựa trên việc sử dụng đồng thời: một nhánh truy vấn *vec-tơ nguyên mẫu liên tục* (*continuous prototypes*) và một nhánh truy vấn *vec-tơ nguyên mẫu rời rạc* (*discrete prototypes*).

Phương pháp đề xuất sẽ được đánh giá trên các bộ dữ liệu tổng quan (general dataset) trong bài toán TSAD như SMD, SMAP, MSL, SWaT. Các độ đo (metric) mà chúng tôi sẽ sử dụng bao gồm nhưng không giới hạn trong: độ chuẩn xác (precision), độ bao phủ (recall), F1-score, diện tích dưới đường cong AUC (ROC-AUC), diện tích dưới đường cong PR (ROC-PR), và các độ đo chuyên biệt cho bài toán TSAD như Range-AUC-ROC, Range-AUC-PR.

Ngoài các độ đo chuẩn (standard metrics) bên trên, chúng tôi cũng sẽ đo mức độ mô hình sử dụng các vec-tơ nguyên mẫu rời rạc, bằng cách tính toán entropy của phân phối mà chúng tôi sử dụng trong cơ chế truy vấn. Dựa trên số liệu định lượng trong kết quả thí nghiệm, chúng tôi cũng sẽ quyết định thiết kế hay không cơ chế điều chỉnh (regularization) giữa hai nhánh, để tránh việc mô hình lạm dụng kiến thức của một nhánh mà không học nhánh còn lại, đồng thời, làm cho biểu diễn học được giữa hai nhánh khác nhau về mặt ngữ nghĩa, tạo ra sự đa dạng trong không gian biểu diễn.

0.2.2 Mục tiêu đề tài

Việc thực hiện nghiên cứu đề tài này sẽ giúp đề xuất được phương pháp để định lượng sự không chắc chắn của mô hình, dựa trên cơ sở lý thuyết trong lĩnh vực *học biểu diễn sâu* (*deep representation learning*), ứng dụng trong *học biểu diễn chuỗi thời gian* (*deep representation learn-*

ing of time window). Hơn nữa, đề tài cũng sẽ cung cấp phương pháp để thích ứng mô hình trong bối cảnh chuỗi thời gian có tính không dừng.

Bằng cách cung cấp định lượng bất định và khả năng thích ứng, kết quả của đề tài sẽ giúp các mô hình TSAD hoạt động được một cách đáng tin cậy và hiệu quả hơn trong các bối cảnh dòng dữ liệu thời gian có tính không dừng.

0.2.3 Phạm vi của đề tài

Đối tượng nghiên cứu chính của đề tài là cơ chế học biểu diễn của các mô hình học sâu sử dụng trong TSAD và đối tượng *ten-xơ biểu diễn* (*representation tensors*) mà các mô hình học được.

Các thực thể liên quan bao gồm các khung kiến trúc mô hình học sâu (backbone) được sử dụng trong TSAD như Residual Convolutional Network (gọi tắt là ResNet) [8], hay các backbone sử dụng cơ chế Attention như Transformer [9], và còn nhiều backbone khác.

Các tập dữ liệu có thể được sử dụng trong đề tài bao gồm: Server Machine Dataset (SMD) [10], Soil Moisture Active Passive (SMAP) [11], Mars Science Laboratory (MSL) [11], Secure Water Treatment (SWaT) [12].

Để đánh giá hiệu quả của mô hình (model performance) trên các dòng dữ liệu có tính không dừng, chúng tôi sẽ lựa chọn sử dụng bộ dữ liệu SWaT, và các thực thể (data entity) sau trong bộ dữ liệu SMD: SMD 1-7, 1-8, 2-1, 2-4, và 3-2. Lí do là vì trong các đối tượng này, có sự thay đổi về mặt phân phối giữa chuỗi huấn luyện (training series) và chuỗi kiểm tra được gán nhãn (labeled testing series) [13].

0.2.4 Cách tiếp cận dự kiến

Tuy có độ chính xác cao, các phương pháp reconstruction-based thường gặp phải một khó khăn chung là mô hình có thể vô tình học cách tái tạo các mẫu hình bất thường, đây gọi là hiện tượng *tổng quát*

hoá quá mức (*overgeneralization*). Để giải quyết vấn đề này, các phương pháp gần đây đã đề xuất sử dụng các *vec-tơ bộ nhớ* (*memory / prototype vectors*) để lưu các mẫu hình bình thường trong quá trình huấn luyện và dùng các vec-tơ này để tái tạo chuỗi đầu vào, làm giới hạn khả năng tái tạo lại các mẫu hình bất thường của mô hình [14] [15] [16]. Bằng cách này, các phương pháp học kèm theo bộ nhớ thường ít tái tạo lại các chuỗi có chứa bất thường.





Figure 6: The t-SNE graphs of the original data and the data reconstructed by H-PAD.

Hình 1: Trực quan hoá kết quả tái tạo chuỗi của phương pháp H-PAD. Nguồn ảnh trong bài báo gốc [15]

Tuy vậy, các phương pháp hiện tại có sử dụng cơ chế bộ nhớ chủ yếu lưu trữ các *vec-tơ nguyên mẫu liên tục* (*continuous prototypes*). Trong khi đó, việc kết hợp đồng thời vec-tơ nguyên mẫu liên tục với *vec-tơ nguyên mẫu rời rạc* (*discrete prototypes / codebook*) vẫn chưa được khai thác nhiều. Vì vậy, tiềm năng bổ sung lẫn nhau giữa hai dạng biểu diễn này vẫn chưa được nghiên cứu đầy đủ. Cụ thể, trong khi các vec-


tơ liên tục có khả năng biểu diễn linh hoạt và bảo toàn tốt thông tin ngữ nghĩa, các vec-tơ rời rạc có ưu thế về *lượng tử hóa* (*quantize*) biểu diễn và *nén dữ liệu* (*data compression*). Trong đề tài này, chúng tôi kỳ vọng rằng việc phối hợp hai loại vec-tơ trên sẽ giúp xây dựng *các biểu diễn chuyên biệt* (*more specialized representations*) hơn, từ đó hỗ trợ hiệu quả cho các khung học đa tác vụ (*multi-task learning*), chẳng hạn như đồng thời tối ưu *tác vụ phân lớp* (*classification*) và *tác vụ tái tạo chuỗi* (*reconstruction*). Việc sử dụng khung học đa tác vụ trong phương pháp cũng sẽ giúp mô hình học được các biểu diễn có tính tổng quát (*generality*) cao hơn [17]. Đồng thời, chúng tôi sẽ đề xuất phương pháp định lượng độ bất định phù hợp với cơ chế của từng loại vec-tơ nguyên mẫu. Cụ thể là, khi một *vec-tơ ẩn* (*latent representation*) truy vấn để các vec-tơ nguyên mẫu chứa giá trị liên tục, chúng tôi sẽ đặt một phân phối xác suất lên các trọng số truy vấn đầu ra để đại diện cho *độ bất định trong thao tác kết hợp* (*uncertainty in linear combination*) các vec-tơ nguyên mẫu liên tục, có thể là phân phối xác suất trong các bài báo [18] [19]. Điểm khác biệt ở đây là chúng tôi sẽ xem việc truy vấn đến các vec-tơ nguyên mẫu rời rạc giống như thao tác cross-attention và đặt một phân phối lên các vec-tơ trọng số attention. Đối với trường hợp vec-tơ nguyên mẫu là các vec-tơ chứa giá trị rời rạc, chúng tôi sẽ sử dụng phương pháp trong bài báo [20] để đại diện cho độ bất định trong việc chọn ra 1 vec-tơ nguyên mẫu *gần nhất* (*nearest*) với vec-tơ ẩn. Sau khi sử dụng vec-tơ ẩn để truy vấn đến hai nguyên mẫu, mô hình sẽ tổng hợp (fuse) kết quả từ hai nhánh sử dụng hai bộ tổng hợp (head) khác nhau, mỗi bộ tổng hợp tương ứng với một tác vụ trong khung học đa tác vụ. Như đã nói trong phần 2.1, chúng tôi sẽ căn cứ vào kết quả thí nghiệm để quyết định sẽ thiết kế hay không cơ chế điều chỉnh (regularization) để đảm bảo mô hình không lạm dụng một nhánh cho bất kỳ tác vụ nào, đồng thời tạo ra sự đa dạng về mặt ngữ nghĩa giữa hai nhánh. Cơ chế mà chúng tôi sử dụng sẽ có điểm tương đồng với cơ chế được trình bày trong hai bài báo [21] và [22].



Hình 2: Dự kiến kiến trúc của mô hình

Một vấn đề khác chúng tôi muốn thảo luận là, các phương pháp phát hiện bất thường chuỗi thời gian (time series anomaly detection, TSAD) hiện nay vẫn còn tương đối hạn chế trong việc thích ứng trực tuyến (online adaptation) khi dữ liệu đầu vào có tính không dừng (non-stationary), hoặc khi dòng dữ liệu quan sát thuộc miền khác với miền dữ liệu huấn luyện (domain adaptation). Trong phạm vi đề tài này, chúng tôi hướng đến việc đề xuất một cơ chế thích ứng mô hình theo sự thay đổi phân phối của từng online mini-batch. Cụ thể, phương pháp được xây dựng theo hướng căn chỉnh (align) biểu diễn của các mẫu trong

online mini-batch với các biểu diễn tham chiếu trong phân phối của tập huấn luyện. Ý tưởng này được lấy cảm hứng từ phương pháp trong bài báo [23]. Tuy nhiên, điểm khác biệt của đề tài là chúng tôi sẽ thiết kế một hàm mất mát tương phản (contrastive loss) nhằm đồng thời kéo các biểu diễn trong mini-batch lại gần các biểu diễn chuẩn trong tập huấn luyện và các vec-tơ nguyên mẫu (prototype vectors), qua đó hỗ trợ mô hình thích ứng tốt hơn với sự thay đổi phân phối dữ liệu theo thời gian.



Hình 3: Dự kiến phương pháp thích ứng online

Tóm lại, trong đề tài này, chúng tôi sẽ đề xuất những ý chính sau:

- Chúng tôi sẽ sử dụng một mô-đun vec-tơ nguyên mẫu liên tục và một mô-đun vec-tơ nguyên mẫu rời rạc. Sau đó, chúng tôi đề xuất kết hợp (fuse) kết quả từ hai mô-đun này để tạo thành các biểu diễn chuyên biệt cho từng tác vụ trong khung huấn luyện đa tác vụ.
- Chúng tôi đề xuất áp dụng phương pháp định lượng độ bất định trong cơ chế truy vấn của từng loại nguyên mẫu tương ứng.

- Chúng tôi thiết kế một hàm mất mát tương phản (contrastive loss) để căn chỉnh biểu diễn trực tuyến với biểu diễn tham chiếu tương ứng.

0.2.5 Kết quả dự kiến của đề tài

Kết quả dự kiến của đề tài sẽ bao gồm số liệu định lượng, sản phẩm đầu ra và, trong trường hợp tốt nhất, sẽ bao gồm bài báo khoa học.

- Số liệu định lượng sẽ bao gồm các thông số như độ chính xác (precision), độ bao phủ (recall) và F1-score.
- Sản phẩm đầu ra sẽ bao gồm mã nguồn dưới dạng GitHub repository, các dữ liệu liên quan trong Google Drive và các số liệu đo đạc được trong quá trình thí nghiệm.
- Bài báo khoa học, trong trường hợp tốt nhất, sẽ được nộp đến một hội nghị hoặc tạp chí uy tín trong lĩnh vực Khai thác dữ liệu (Data Mining) và Học máy (Machine Learning).

0.2.6 Kế hoạch thực hiện

Bảng 1: Kế hoạch thực hiện và phân chia công việc

Thời gian	Nội dung công việc	Người thực hiện	Kết quả dự kiến
Tháng 1	Khảo sát các nghiên cứu trước, xác định bài toán nghiên cứu	Nguyễn Anh Khôi	Tổng quan các nghiên cứu trước và xác định hướng nghiên cứu
Tháng 2,3	Đề xuất phương pháp và mô hình	Nguyễn Anh Khôi	Phương pháp và mô hình dự kiến
Tháng 4	Lập trình và thực hiện thí nghiệm	Nguyễn Anh Khôi	Mã nguồn thí nghiệm và kết quả định lượng của phương pháp và mô hình
Tháng 5	Lặp lại: đánh giá, thí nghiệm và cải tiến, tinh chỉnh phương pháp và mô hình	Nguyễn Anh Khôi	Các kết quả định lượng thêm từ thí nghiệm, các cải tiến nhỏ để hoàn thiện phương pháp và mô hình
Tháng 6	Viết báo cáo tổng kết đề tài và bài báo khoa học (nếu có)	Nguyễn Anh Khôi	Bản thảo báo cáo tổng kết đề tài và bài báo khoa học (nếu có)
Tháng 7	Hoàn thiện báo cáo tổng kết đề tài và nộp bài báo khoa học (nếu có)	Nguyễn Anh Khôi	Báo cáo tổng kết đề tài và bài báo khoa học (nếu có)

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 06 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Tài liệu

- [1] Lehman, L.-w. et al., “Vtac: A benchmark dataset of ventricular tachycardia alarms from icu monitors,” in *Advances in Neural Information Processing Systems*, Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., and Levine, S., Eds., vol. 36, Curran Associates, Inc., 2023, pp. 38 827–38 843. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2023/file/7a53bf4e02022aad32a4019d41b3b476-Paper-Datasets_and_Benchmarks.pdf.
- [2] Gabrielli, D., Prenkaj, B., Velardi, P., and Faralli, S., “Ai on the pulse: Real-time health anomaly detection with wearable and ambient intelligence,” in *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*, ser. CIKM ’25, New York, NY, USA: Association for Computing Machinery, 2025, pp. 4717–4721. DOI: 10.1145/3746252.3760799. [Online]. Available: <https://doi.org/10.1145/3746252.3760799>.
- [3] Chen, F. et al., “Cluster-wide task slowdown detection in cloud system,” in *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, ser. KDD ’24, New York, NY, USA: Association for Computing Machinery, 2024, pp. 266–277. DOI: 10.1145/3637528.3671936. [Online]. Available: <https://doi.org/10.1145/3637528.3671936>.
- [4] Zamanzadeh Darban, Z., Webb, G. I., Pan, S., Aggarwal, C., and Salehi, M., “Deep learning for time series anomaly detection: A survey,” *ACM Comput. Surv.*, vol. 57, no. 1, Oct. 2024, ISSN: 0360-0300. DOI: 10.1145/3691338. [Online]. Available: <https://doi.org/10.1145/3691338>.
- [5] Obata, K., Matsubara, Y., and Sakurai, Y., “Robust and explainable detector of time series anomaly via augmenting multiclass

- pseudo-anomalies,” in *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2*, ser. KDD ’25, New York, NY, USA: Association for Computing Machinery, 2025, pp. 2198–2209. DOI: 10.1145/3711896.3737110. [Online]. Available: <https://doi.org/10.1145/3711896.3737110>.
- [6] Jeong, J. and Yoon, H., “PGRF-net: A prototype-guided relational fusion network for diagnostic multivariate time-series anomaly detection,” in *The Fourteenth International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=3hS7EtL4bV>.
- [7] Darban, Z. Z., Webb, G. I., Pan, S., Aggarwal, C. C., and Salehi, M., “CARLA: Self-supervised contrastive representation learning for time series anomaly detection,” *Pattern Recognition*, vol. 157, p. 110 874, 2025, ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110874>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0031320324006253>.
- [8] He, K., Zhang, X., Ren, S., and Sun, J., “Deep residual learning for image recognition,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90.
- [9] Vaswani, A. et al., “Attention is all you need,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17, Red Hook, NY, USA: Curran Associates Inc., 2017, pp. 6000–6010.
- [10] Su, Y., Zhao, Y., Niu, C., Liu, R., Sun, W., and Pei, D., “Robust anomaly detection for multivariate time series through stochastic recurrent neural network,” in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, ser. KDD ’19, New York, NY, USA: Association for Computing Machinery, 2019, pp. 2828–2837. DOI: 10.1145/3292500.33

30672. [Online]. Available: <https://doi.org/10.1145/3292500.3330672>.
- [11] Hundman, K., Constantinou, V., Laporte, C., Colwell, I., and Soderstrom, T., “Detecting spacecraft anomalies using lstms and non-parametric dynamic thresholding,” in *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, ser. KDD ’18, New York, NY, USA: Association for Computing Machinery, 2018, pp. 387–395. DOI: 10.1145/3219819.3219845. [Online]. Available: <https://doi.org/10.1145/3219819.3219845>.
 - [12] Goh, J., Adepu, S., Junejo, K. N., and Mathur, A., “A dataset to support research in the design of secure water treatment systems,” in *Critical Information Infrastructures Security*, Havarneanu, G., Setola, R., Nassopoulos, H., and Wolthusen, S., Eds., Cham: Springer International Publishing, 2017, pp. 88–99.
 - [13] Kim, H., Mok, J., Lee, H., Shin, J., and Yoon, S., “Candi: Curated test-time adaptation for multivariate time-series anomaly detection under distribution shift,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 40, no. 17, pp. 15 018–15 026, Mar. 2026. DOI: 10.1609/aaai.v40i17.38524. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/38524>.
 - [14] Song, J., Kim, K., Oh, J., and Cho, S., “Memto: Memory-guided transformer for multivariate time series anomaly detection,” in *Proceedings of the 37th International Conference on Neural Information Processing Systems*, ser. NIPS ’23, Red Hook, NY, USA: Curran Associates Inc., 2023.
 - [15] Li, C.-G., “Learn hybrid prototypes for multivariate time series anomaly detection,” in *The Thirteenth International Conference on Learning Representations*, 2025. [Online]. Available: <https://openreview.net/forum?id=8TBGdH3t6a>.

- [16] Xie, Y., Zhang, H., and Babar, M. A., “Multivariate time series anomaly detection by capturing coarse-grained intra- and inter-variate dependencies,” in *Proceedings of the ACM on Web Conference 2025*, ser. WWW ’25, New York, NY, USA: Association for Computing Machinery, 2025, pp. 697–705. DOI: 10.1145/3696410.3714941. [Online]. Available: <https://doi.org/10.1145/3696410.3714941>.
- [17] Zhou, K., Liu, Z., Qiao, Y., Xiang, T., and Loy, C. C., “Domain generalization: A survey,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 45, no. 4, pp. 4396–4415, Apr. 2023, ISSN: 0162-8828. DOI: 10.1109/TPAMI.2022.3195549. [Online]. Available: <https://doi.org/10.1109/TPAMI.2022.3195549>.
- [18] Fan, X., Zhang, S., Chen, B., and Zhou, M., “Bayesian attention modules,” in *Proceedings of the 34th International Conference on Neural Information Processing Systems*, ser. NIPS ’20, Red Hook, NY, USA: Curran Associates Inc., 2020.
- [19] Pei, J., Wang, C., and Szarvas, G., “Transformer uncertainty estimation with hierarchical stochastic attention,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 36, no. 10, pp. 11 147–11 155, Jun. 2022. DOI: 10.1609/aaai.v36i10.21364. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/21364>.
- [20] Ramesh, A. et al., “Zero-shot text-to-image generation,” in *Proceedings of the 38th International Conference on Machine Learning*, Meila, M. and Zhang, T., Eds., ser. Proceedings of Machine Learning Research, vol. 139, PMLR, 18–24 Jul 2021, pp. 8821–8831. [Online]. Available: <https://proceedings.mlr.press/v139/ramesh21a.html>.
- [21] Bardes, A., Ponce, J., and LeCun, Y., “Vicreg: Variance-invariance-covariance regularization for self-supervised learning,” in *International Conference on Learning Representations (ICLR)*, 2022. [On-

line]. Available: <https://openreview.net/forum?id=xm6YD62D1Ub>.

- [22] Kim, J. and Yoon, K.-J., “Gated temporal fusion transformers for robust multi-object tracking,” in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, Jan. 2026, pp. 4525–4533.
- [23] Zhang, Z.-Y., Xie, Z., Yao, H., and Sugiyama, M., “Test-time adaptation in non-stationary environments via adaptive representation alignment,” in *Proceedings of the 38th International Conference on Neural Information Processing Systems*, ser. NIPS ’24, Red Hook, NY, USA: Curran Associates Inc., 2024.

Mục lục

Lời cảm ơn	ii
0.1 THÔNG TIN CHUNG	iii
0.2 NỘI DUNG THỰC HIỆN	iv
0.2.1 Giới thiệu về đề tài	iv
0.2.2 Mục tiêu đề tài	vi
0.2.3 Phạm vi của đề tài	vii
0.2.4 Cách tiếp cận dự kiến	vii
0.2.5 Kết quả dự kiến của đề tài	xii
0.2.6 Kế hoạch thực hiện	xiii
Đề cương	iii
Mục lục	xix
Danh sách hình vẽ	xxii
Danh sách bảng	xxiii
Tóm tắt	xxiii
1 Giới thiệu đề tài	1
2 Các công trình liên quan	5
2.1 Phát hiện bất thường trên chuỗi thời gian đa biến sử dụng mạng nơ-ron sâu	6

2.2	Phát hiện bất thường trên chuỗi thời gian đa biến có sử dụng bộ nhớ hỗ trợ	9
2.3	Thích ứng khi kiểm thử trực tuyến cho bài toán phát hiện bất thường chuỗi thời gian	10
2.4	Ước lượng bất định nhận thức	11
2.4.1	Các độ đo	14
3	Phương pháp đề xuất	17
3.1	Kiến trúc mạng nơ-ron	18
3.1.1	Bộ mã hoá chia sẻ chung	19
3.1.2	Hai bộ nhớ và hai toán tử truy vấn tương ứng	21
3.2	Quy trình tiền huấn luyện và hàm mất mát tương ứng	26
3.3	Quy trình thích ứng trực tuyến trên dòng dữ liệu và hàm mất mát tương ứng	35
3.3.1	Nhánh biểu diễn nguồn và bộ ánh xạ trực tuyến	37
3.3.2	Ngưỡng bất thường trực tuyến và cơ chế phân luồng cửa sổ trực tuyến	38
3.3.3	Thích ứng mạng với các mẫu hình bình thường khó	41
3.3.4	Thích ứng với các mẫu hình giả định bình thường mới đã được xác minh	43
4	Thiết kế thực nghiệm và Kết quả thực nghiệm	47
4.1	Thiết kế thực nghiệm	48
4.2	Kết quả thực nghiệm	49
5	Kết luận và hướng nghiên cứu tương lai	53
	Tài liệu tham khảo	54

Danh sách hình vẽ

1	Trực quan hoá kết quả tái tạo chuỗi của phương pháp H-PAD. Nguồn ảnh trong bài báo gốc [15]	viii
2	Dự kiến kiến trúc của mô hình	x
3	Dự kiến phương pháp thích ứng online	xi
3.1	Kiến trúc của mô hình mà chúng tôi đề xuất.	18
3.2	Kiến trúc mô hình trong giai đoạn A của pha ngoại tuyến.	27
3.3	Các lớp bất thường nhân tạo từ 0 đến 5.	28
3.4	Các lớp bất thường nhân tạo từ 6 đến 11.	29
3.5	Kiến trúc mô hình trong giai đoạn B của pha ngoại tuyến.	32
3.6	Kiến trúc mô hình trong pha trực tuyến.	37

Danh sách bảng

1	Kế hoạch thực hiện và phân chia công việc	xiii
2.1	Một số phương pháp phát hiện bất thường chuỗi thời gian sử dụng mạng nơ-ron trong giai đoạn 2024–2026.	8
4.1	Số lượng cửa sổ với độ dài 20 trong các tập huấn luyện, tập xác thực và tập kiểm tra.	48
4.2	So sánh hiệu quả pha ngoại tuyến của phương pháp đề xuất với các phương pháp đối sánh.	50
4.3	Quan sát độ bất định của mạng nơ-ron trong pha ngoại tuyến.	51
4.4	Kết quả cuối cùng ở pha online của THESIS, M2N2 và CANDI.	51

Tóm tắt

Phát hiện bất thường chuỗi thời gian là một bài toán được ứng dụng trong nhiều lĩnh vực quan trọng [1] [2] [3]. Tuy nhiên, chưa có nhiều phương pháp kết hợp *học biểu diễn đa nhiệm (multi-task representation learning)* và *cơ chế bộ nhớ (memory bank)*. Bên cạnh đó, *ước lượng độ bất định nhận thức (epistemic uncertainty estimation)* của mô hình và *thích ứng mô hình trên môi trường trực tuyến (online adaptation)* cũng là các vấn đề chưa được quan tâm đủ nhiều. Trong báo cáo này, chúng tôi đề xuất 2 toán tử truy vấn tương ứng với một bộ nhớ liên tục và một bộ nhớ rời rạc nhằm tính toán được biểu diễn chuyên biệt cho mỗi tác vụ. Chúng tôi cũng đề xuất 2 phiên bản ngẫu nhiên tương ứng cho hai toán tử đó nhằm ước lượng được độ bất định nhận thức của mô hình. Thêm vào đó, chúng tôi đề xuất một khung thích ứng trực tuyến dựa trên hàm mất mát tương phản offline–online và cơ chế *bộ đệm xác minh (verification buffer)* để phát hiện và thích ứng trên các cửa sổ được xem là chứa *mẫu hình bình thường mới (new normality)*. Kết quả thực nghiệm cho thấy phương pháp đề xuất có tốt hơn các phương pháp đối sánh trên các độ đo VUS-PR và Affiliation F1-score trong cả pha tiền huấn luyện ngoại tuyến và thích ứng trực tuyến. Thông qua phân tích thực nghiệm, chúng tôi kết luận rằng mức tăng trong các độ đo hiệu quả phần lớn đến từ hai mô-đun toán tử truy vấn (trong pha ngoại tuyến) và cơ chế làm mượt (trong pha trực tuyến). Ngoài ra, hai phiên bản ngẫu nhiên của hai toán tử truy vấn cũng cho thấy kết quả khả quan trong ước lượng độ bất định.

Chương 1

Giới thiệu đề tài

Phát hiện bất thường chuỗi thời gian (TSAD - Time Series Anomaly Detection) là một bài toán có nhiều ứng dụng trong các lĩnh vực quan trọng như sản xuất chất bán dẫn [4], giám sát hạ tầng điện toán đám mây [1] [5] [6], điều trị nội trú và ngoại trú trong lĩnh vực y tế [2], và nhiều ứng dụng khác. Các phương pháp TSAD thường dựa trên hai tác vụ học (*learning task*) chính là *dự báo (forecasting)* và *tái tạo chuỗi (reconstruction)*. Trong đó, các phương pháp TSAD *dựa trên tác vụ tái tạo chuỗi (reconstruction-based)* thường được sử dụng để phát hiện bất thường trong các lĩnh vực cần độ chính xác cao, do mô hình trong các phương pháp này dự đoán dựa trên dữ liệu mới nhất, không giống như các phương pháp *dựa trên tác vụ dự báo (forecasting-based)* thường dựa trên dữ liệu lịch sử để dự đoán dữ liệu mới nhất. Trọng tâm của đề tài này là các phương pháp TSAD dựa trên tác vụ tái tạo chuỗi. Sau đây, chúng tôi sẽ thảo luận về khía cạnh dữ liệu của bài toán TSAD.

Gán nhãn bất thường cho dữ liệu chuỗi thời gian là một quá trình *rất tốn nhân công (labor-intensive)*. Tuy nhiên, kể cả dữ liệu chuỗi thời gian đã được gán nhãn bình thường cũng luôn có khả năng bị *nhiễm bất thường*. Hai lí do trên là động lực chính để một số phương pháp hiện nay sử dụng các kỹ thuật *gia tăng dữ liệu (data-augmentation)* để thu được các mẫu, với một mẫu thường là một *cửa sổ trượt*, có chứa *bất thường nhân tạo (synthetic anomaly)* [7] [8] [9]. Bằng cách này, mô hình sẽ có nhiều dữ liệu hơn để học cách trích xuất các mẫu hình bất thường. Đồng thời, các bất thường nhân tạo có thể vô tình gần giống với các bất thường thật chưa được gán nhãn trong dữ liệu bình thường. Điều này giúp mô hình tách biệt được rõ hơn các mẫu hình bất thường và các mẫu hình thật sự bình thường, bỏ qua *giả định rằng chuỗi huấn luyện hoàn toàn bình thường (normality assumption)*.

Hiện nay, các phương pháp gia tăng số lượng mẫu dữ liệu bất thường dựa trên một trong hai giả định phổ biến là: *giả định nhị phân về bất thường (binary anomaly assumption)*, nghĩa là có một lớp bình thường và một lớp bất thường, và *giả định đa lớp về bất thường (multi-class*

anomaly assumption), nghĩa là có một lớp bình thường và nhiều lớp bất thường. Hai *tác vụ học (learning task)* tương ứng với hai giả định này là *phân loại nhị phân (binary classification)* và *phân loại đa lớp (multi-class classification)*.

Gần đây, các phương pháp TSAD sử dụng mạng nơ-ron sâu (deep neural networks), bao gồm các phương pháp sử dụng kỹ thuật gia tăng dữ liệu, đã cho thấy kết quả khả quan. Tuy nhiên, việc định lượng độ bất định *độ bất định của mô hình (epistemic uncertainty)* [1] trong tác vụ TSAD là một vấn đề chưa được quan tâm và nghiên cứu đủ nhiều. Những phương pháp không định lượng độ bất định của mô hình sẽ không nhận biết được *mức độ tự tin (confidence)* và *mức độ bất định (uncertainty)* của mô hình, đặc biệt khi sử dụng mô hình trên *dòng dữ liệu chuỗi thời gian (time-series stream)* sinh ra từ phân phối khác với *phân phối của tập huấn luyện (training distribution)*. Điều này làm giới hạn khả năng ứng dụng các phương pháp này trong các lĩnh vực rủi ro cao (high-stakes) như y tế kỹ thuật cao, tài chính - ngân hàng, và nhiều lĩnh vực khác.

Nhìn chung, các phương pháp hiện nay có hai hạn chế chung như sau:

- (1) Chưa lượng hoá được *độ bất định (uncertainty)* trong kết quả phân lớp hay trong kết quả phát hiện bất thường.
- (2) Chưa thích ứng được mô hình một cách liên tục (*continual adaptation*) và hiệu quả (*efficiency*) trên các *dòng dữ liệu thời gian có tính không dừng (non-stationary streaming time series)*.

Để giải quyết hai vấn đề trên, trong báo cáo này, chúng tôi đề xuất một phương pháp để định lượng độ bất định của mô hình thông qua sử dụng hàm Gumbel-Softmax [10] trong cơ chế *truy vấn nguyên mẫu (querying prototypes)*. Để đảm bảo thuật toán lan truyền ngược có thể tính toán gradient một cách đầy đủ, chúng tôi sử dụng *kỹ thuật tái tham số hoá (re-parametrization technique)* để *dòng gradient (gradient flow)* có thể đi qua hàm Gumbel-Softmax này và đến được các mô-đun trước đó của mạng nơ-ron. Đồng thời, chúng tôi cũng đề xuất một phương

pháp để thích ứng mô hình trên dòng dữ liệu thời gian có tính không dừng, với mục tiêu là đưa *vec-tơ biểu diễn sâu tại thời điểm trực tuyến* (*online representation vector*) về gần với biểu diễn sâu mà mô hình học được sau khi trải qua quá trình *tiền huấn luyện* (*pre-training*), hay còn gọi là *vec-tơ biểu diễn nguồn* (*source representation vector*). Ngoài ra, chúng tôi cũng sẽ đề xuất một phương pháp cải tiến biểu diễn mà mô hình học được, sao cho cho mỗi tác vụ trong *khung huấn luyện đa tác vụ* (*multi-task learning framework*) mà chúng tôi sử dụng sẽ có biểu diễn chuyên biệt tương ứng, dựa trên việc sử dụng đồng thời: một nhánh truy vấn liên tục các vec-tơ nguyên mẫu (*continuous query operator*) và một nhánh truy vấn rời rạc vec-tơ nguyên mẫu (*discrete query operator*).

Tóm tắt lại thì trong báo cáo này chúng tôi sẽ đề xuất những điều sau:

- (1) Một toán tử truy vấn liên tục các vec-tơ nguyên mẫu và một toán tử truy vấn rời rạc các vec-tơ nguyên mẫu, kèm theo hai phiên bản *truy vấn ngẫu nhiên* (*stochastic query*) tương ứng.
- (2) Một khung thích ứng trực tuyến để kéo vec-tơ biểu diễn trực tuyến về gần với vec-tơ biểu diễn gốc tương ứng, hay nói cách khác là đảm bảo *bộ mã hoá trực tuyến* (*online encoder*) không trôi quá xa *bộ mã hoá nguồn* (*source encoder*).
- (3) Một cơ chế bộ đệm (verification buffer) để lọc ra các cửa sổ dùng cho *quá trình cập nhật trọng số trực tuyến* (*online stochastic gradient descent*). Điều kiện lọc sẽ được trình bày cụ thể trong *Chương 3. Phương pháp đề xuất*.

Chương 2

Các công trình liên quan

2.1 Phát hiện bất thường trên chuỗi thời gian đa biến sử dụng mạng nơ-ron sâu

Các phương pháp học sâu được đề xuất gần đây, cụ thể là từ năm 2024 đến tháng 7 năm 2026, cho bài toán *phát hiện bất thường trên chuỗi thời gian đa biến (MTSAD)* thường sẽ học cách **dự đoán (predict)** giá trị kỳ vọng (*expected value*) của một mẫu dữ liệu dựa trên các mẫu hình đã được mã hoá (encoded) vào ten-xơ tham số (parameter tensors) của mô hình backbone và **ra quyết định (make decision)** một mẫu dữ liệu (sample) là bình thường hay bất thường dựa vào độ lệch (deviations) giữa giá trị kỳ vọng của mẫu và giá trị của cùng mẫu đó mà mô hình thật sự nhận được. Tùy vào phương pháp cụ thể mà độ lệch đó có thể là độ lệch tái tạo chuỗi (reconstruction error) [11][12][13], độ lệch dự báo chuỗi (forecasting residual) [12][14][15], độ lệch so với các vec-tơ nguyên mẫu đại diện cho mẫu hình bình thường (deviations from normal prototypes) [16][17][18], và nhiều cách tính toán độ lệch khác [19][14][20][21]. Trong đó, ra quyết định phát hiện bất thường dựa vào độ lệch tái tạo chuỗi thường được sử dụng trong các ứng dụng yêu cầu độ chính xác cao [22]. Đối với một cửa sổ tại bước thời gian t , công thức của độ lệch tái tạo thường được viết một cách tường minh như sau:

$$\begin{aligned} E_{\text{rec},t}(\mathbf{X}_t, \hat{\mathbf{X}}_t) &= \text{MSE}(\mathbf{X}_t, \hat{\mathbf{X}}_t) \\ &= \frac{1}{TD} \sum_{s=t-T+1}^t \sum_{d=1}^D (x_{s,d} - \hat{x}_{s,d})^2 \\ &= \frac{1}{TD} \left[(x_{t-T+1,1} - \hat{x}_{t-T+1,1})^2 + \cdots + (x_{t-T+1,D} - \hat{x}_{t-T+1,D})^2 \right. \\ &\quad + (x_{t-T+2,1} - \hat{x}_{t-T+2,1})^2 + \cdots + (x_{t-T+2,D} - \hat{x}_{t-T+2,D})^2 \\ &\quad + \cdots \\ &\quad \left. + (x_{t,1} - \hat{x}_{t,1})^2 + \cdots + (x_{t,D} - \hat{x}_{t,D})^2 \right]. \end{aligned} \tag{2.1}$$

Trong đó:

- T là số bước thời gian trong một cửa sổ;
- D là số biến;
- $x_{t,d}$ là giá trị thật sự quan sát được của biến d tại thời điểm t ;
- $\hat{x}_{t,d}$ là giá trị được tái tạo của biến d tại thời điểm t . Đây là giá trị mà mô hình kì vọng;
- $E_{\text{rec},t}$ là độ lệch tái tạo. Giá trị $E_{\text{rec},t}$ càng lớn thì chuỗi quan sát được $\mathbf{X}_t$ càng khác chuỗi kỳ vọng $\hat{\mathbf{X}}_t$. Khi độ lệch này vượt qua một ngưỡng τ nào đó thì mô hình quyết định cửa sổ quan sát được là bất thường.

Chúng tôi in đậm hai từ **dự đoán** giá trị kỳ vọng và **ra quyết định** phát hiện bất thường để người đọc phân biệt được rõ ràng hơn hai quá trình này trong bất kì phương pháp MTSAD nào.

Bảng 2.1: Một số phương pháp phát hiện bất thường chuỗi thời gian sử dụng mạng nơ-ron trong giai đoạn 2024–2026.

Năm	Tên phương pháp	Nơi công bố	Các từ khoá
2024	ContraAD [23]	PVLDB	<i>cross contrastive learning; cross-timestamp discrepancy; anomaly-boundary-guided optimization</i>
2024	DualTF [24]	WWW	<i>time-frequency granularity alignment; dual-domain representation; cross-granularity alignment</i>
2025	CATCH [25]	ICLR	<i>frequency patching; channel masking; channel-aware frequency dependencies</i>
2025	DADA [26]	ICLR	<i>adaptive bottleneck; complementary masking; dual adversarial decoders</i>
2026	Adaptive Conformal AD [27]	ICLR	<i>foundation-model residual nonconformity; adaptive conformal calibration; sequential p-values; false-alarm control</i>
2026	DESS [11]	WWW	<i>evolving proxy; proxy-guided update; streaming concept-drift adaptation</i>
2026	GBOC [16]	AAAI	<i>granular-ball vector data description; density-guided splitting; nearest-ball alignment</i>
2026	HEIGHTS [12]	Neurocomputing	<i>hierarchical graph structure learning; temporal-variable graphs; view-level hierarchical graph</i>
2026	MindTS [28]	ICLR	<i>time-text semantic alignment; condensed interaction; content-condenser reconstruction</i>
2026	PaAno [18]	ICLR	<i>patch-based representation learning; normal-patch embedding bank; patch-neighborhood scoring</i>
2026	PGRF-Net [8]	ICLR	<i>prototype-guided relational fusion; multi-evidence modeling; gated evidence fusion</i>
2026	SACVT [20]	IEEE Internet of Things Journal	<i>step-aware cross-view attention; hierarchical step-token summarization; cross-wafer views</i>
2026	VLM4TS [29]	AAAI	<i>time-series visual rendering; ViT candidate screening; VLM reasoning and refinement</i>
2026	WAVAE [13]	Information Fusion	<i>weak augmentation; mutual-information contrast; adversarial feature alignment</i>

2.2 Phát hiện bất thường trên chuỗi thời gian đa biến có sử dụng bộ nhớ hỗ trợ

Các phương pháp MTSAD dựa trên tái tạo chuỗi có thể gặp một khó khăn là mạng nơ-ron vô tình học được cách tái tạo các mẫu hình bất thường bị nhiễm (contaminated) trong dữ liệu huấn luyện. Hành vi này được gọi là *tổng quát hoá quá mức (over-generalization)* [30] [31]. Để hạn chế hành vi này ở các mạng nơ-ron backbone, tác giả Song và các cộng sự đã đề xuất sử dụng *mô-đun bộ nhớ (memory bank)* để lưu lại các vec-tơ đại diện cho các mẫu hình bình thường, gọi là các nguyên mẫu (prototypes), và thiết kế cơ chế truy vấn nguyên mẫu (query prototypes) với chủ ý là làm giảm khả năng tái tạo các mẫu hình bất thường của mô hình, góp phần hạn chế được hành vi tổng quát hoá quá mức [30]. Tiếp theo sau, tác giả Shen và các cộng sự đề xuất sử dụng đồng thời nguyên mẫu bình thường (normal prototypes) và nguyên mẫu chu kỳ (period prototypes), kèm theo cơ chế truy vấn tương ứng với mỗi loại để giúp mô hình tránh được hiện tượng tổng quát hoá quá mức ở các loại bất thường cụ thể như là bất thường điểm (point anomalies), bất thường khoảng (interval anomalies) và bất thường chu kỳ (period anomalies) [31]. Đầu năm 2026, tác giả Park và các cộng sự đề xuất sử dụng kết hợp các vec-tơ nguyên mẫu trong bộ nhớ với các quyết định khéo léo khác về mặt thiết kế phương pháp như sử dụng hàm mất mát tương phản (contrastive loss), hàm mất mát của tác vụ tiền đề (pretext loss) và hàm tính điểm bất thường (anomaly scoring function) [18].

2.3 Thích ứng khi kiểm thử trực tuyến cho bài toán phát hiện bất thường chuỗi thời gian

Khi triển khai mạng nơ-ron lên môi trường công nghiệp (production environment) để phát hiện bất thường trên chuỗi thời gian, mạng có thể sẽ nhận được các cửa sổ dữ liệu (time window) nằm ngoài phân phối đã học được từ quá trình tiền huấn luyện (pre-training), hiện tượng này gọi là *hiện tượng dịch chuyển phân phối dữ liệu đầu vào (input data distribution shift)*, thường được viết ngắn gọn là “distribution shift”. Hiện tượng này xuất hiện trong nhiều lĩnh vực khác nhau. Trong giám sát trung tâm dữ liệu, tín hiệu đo từ xa (telemetry) đến từ các đơn vị phần cứng, chẳng hạn như đơn vị xử lý đồ họa (Graphics Processing Unit - GPU), đơn vị xử lý trung tâm (Central Processing Unit), bộ nhớ truy xuất ngẫu nhiên (Random Access Memory - RAM), ổ cứng thể rắn (Solid-State Disk - SSD), có thể xuất hiện distribution shift khi thay mới hoặc nâng cấp các đơn vị phần cứng. Hiện tượng này cũng có thể xảy ra khi thay mới hoặc nâng cấp *hệ thống cảm biến đo từ xa (telemetry sensor system)*. Hiện tượng tương tự có thể xảy ra khi nâng cấp hoặc thay mới các tấm pin trong các trang trại điện mặt trời (solar farm).

Năm 2024, tác giả Kim Dong Min và các cộng sự đề xuất sử dụng ước lượng xu hướng (trend estimation), khử xu hướng (detrending) và thích ứng khi kiểm thử tự giám sát (self-supervised test-time adaptation) để học các mẫu hình *bình thường mới (new normality hay new normal patterns)* [32].

Năm 2026, Tác giả Park và các cộng sự đề xuất sử dụng tập mã rời rạc (discrete codebook) để lưu đồng thời mẫu hình bình thường (normal patterns) học được từ tập huấn luyện và mẫu hình bình thường học được trong thời gian kiểm thử (test time). Phương pháp này cập nhật trực tiếp các vec-tơ trong tập mã rời rạc ngay trong thời gian kiểm thử.

Cùng năm 2026, tác giả Kim HuynGi và các cộng sự đề xuất phương pháp thích ứng khi kiểm thử dựa trên các mẫu dữ liệu *nghe là báo động giả* (*potential false positives*) và cập nhật một mạng rất ít tham số (light-weight) nằm trên *kết nối cộng tắt* (*residual connection*) nhằm bảo toàn tri thức và không gian ẩn mà bộ mã hoá đã học được sau quá trình tiền huấn luyện (pre-training) [33].

2.4 Ước lượng bất định nhận thức

Bất định nhận thức (*epistemic uncertainty*) là mức độ không chắc chắn của mô hình do dữ liệu huấn luyện chưa cung cấp đủ thông tin để mô hình học được một hàm dự đoán đáng tin cậy. Bất định nhận thức thường tăng lên khi mô hình tính toán dự đoán trên các mẫu dữ liệu nằm ngoài phân phối của dữ liệu huấn luyện và có thể giảm xuống khi mô hình được huấn luyện trên nhiều dữ liệu hơn. Ngược lại, bất định ngẫu nhiên (*aleatoric uncertainty*) có nguồn gốc từ nhiễu hoặc tính ngẫu nhiên vốn có trong dữ liệu và không thể loại bỏ hoàn toàn được kể cả khi có thêm dữ liệu huấn luyện [34] [35].

Một *mạng nơ-ron tất định* (*deterministic neural networks*) chỉ tạo ra một giá trị dự đoán cho mỗi mẫu dữ liệu đầu vào. Do đó, nếu tồn tại nhiều hơn một cấu hình (hay bộ giá trị) tham số phù hợp hoặc quá trình suy luận (computational process of inference) phù hợp cho cùng một mạng nơ-ron, thì giá trị dự đoán này không cho biết được quyết định của mạng nơ-ron sẽ dao động thế nào qua các cấu hình tham số và các quá trình suy luận khác nhau. Để *ước lượng* (hay *định lượng*) mức độ dao động đó, tác giả Gal và Ghahramani đề xuất sử dụng *cơ chế tắt nơ-ron ngẫu nhiên* (*dropout mechanism*) [36] kể cả trong thời gian kiểm thử và thực hiện nhiều lần *tính toán lan truyền xuôi* (*forward-propagation*) với các *mặt nạ bật tắt* (*dropout mask*) được lấy mẫu độc lập từ cùng một phân phối Bernoulli (independent and identically distributed - i.i.d), biết rằng cơ chế tắt nơ-ron ngẫu nhiên thường chỉ được sử dụng trên dữ liệu

huấn luyện (training data).

Phương pháp này được gọi là **Monte Carlo dropout** và được các tác giả *diễn giải toán học (mathematically formulated)* để trở nên tương đương với một phép xấp xỉ suy luận Bayes (Bayes inference) trên tham số của một mạng nơ-ron [37].

Một hướng tiếp cận khác là huấn luyện nhiều mạng nơ-ron có cùng kiến trúc nhưng có bộ tham số được khởi tạo độc lập và từ cùng một phân phối (i.i.d), sau đó tính toán độ phân tán trên các dự đoán của các mạng này. Hướng tiếp cận này thường được gọi là *tham vấn nhiều mạng sâu (deep ensembles)* [38].

Tác giả Pei và các cộng sự đề xuất một cách tiếp cận khác để tạo ra nhiều kết quả suy luận từ cùng một mạng nơ-ron. Cụ thể, các tác giả lấy mẫu độc lập ngẫu nhiên các trọng số của *cơ chế chú ý (attention mechanism)* [39] từ cùng một phân phối Gumbel-Softmax. Trong bài báo, đây là phân phối có điều kiện trên một tập hợp *các vec-tơ tâm cụm có thể học được (learnable centroids)*. Khi thực hiện nhiều lần lan truyền xuôi (forward-propagation) với các mẫu Gumbel độc lập ngẫu nhiên, mạng nơ-ron có thể tạo ra nhiều ten-xơ biểu diễn (representation tensors) và nhiều giá trị dự đoán (prediction values) khác nhau cho cùng một mẫu dữ liệu đầu vào. *Độ lệch chuẩn (standard deviation)* giữa các giá trị dự đoán này được xem như độ bất định nhận thức (epistemic uncertainty) của mạng nơ-ron [40]. Tuy nhiên, phương pháp này được đề xuất cho các *tác vụ phân loại văn bản (text classification)*, không phải cho bài toán phát hiện bất thường trên chuỗi thời gian.

Đối với một phương pháp phát hiện bất thường chuỗi thời gian (TSAD) dựa trên độ lệch tái tạo, giả sử ta thực hiện M lần *lan truyền xuôi ngẫu nhiên (stochastic forward-propagation)* trên cùng một cửa sổ $\mathbf{X}_t$ với cùng một mạng nơ-ron có sử dụng *cơ chế chú ý ngẫu nhiên (stochastic attention)*. Ở lần lan truyền xuôi thứ m , mạng nơ-ron tạo ra chuỗi tái tạo $\widehat{\mathbf{X}}_t^{(m)}$ và điểm bất thường $s_t^{(m)}$. Điểm bất thường trung bình

của cửa sổ thời gian (time window) đó được tính toán như sau:

$$\begin{aligned}\bar{s}_t &= \frac{1}{M} \sum_{m=1}^M s_t^{(m)} \\ &= \frac{1}{M} \sum_{m=1}^M \text{MSE} \left(\mathbf{X}_t, \hat{\mathbf{X}}_t^{(m)} \right).\end{aligned}\tag{2.2}$$

Mức độ phân tán của điểm bất thường trên cùng một cửa sổ được tính bằng phương sai mẫu, có công thức tính khác với phương sai tổng thể ở mức độ tự do (degree of freedom):

$$U_{\text{score},t} = \frac{1}{M-1} \sum_{m=1}^M \left(s_t^{(m)} - \bar{s}_t \right)^2.\tag{2.3}$$

Trong đó:

- M là số lần truyền xuôi ngẫu nhiên (stochastic forward-propagation) được thực hiện trên cùng một cửa sổ;
- $\hat{\mathbf{X}}_t^{(m)}$ là cửa sổ được mạng nơ-ron tái tạo lại ở lần lan truyền xuôi ngẫu nhiên thứ m ;
- $s_t^{(m)}$ là điểm bất thường thu được ở lần lan truyền xuôi ngẫu nhiên thứ m ;
- $\bar{s}_t$ là điểm bất thường trung bình của cửa sổ;
- $U_{\text{score},t}$ là phương sai mẫu của điểm bất thường. Giá trị này thể hiện mức độ không chắc chắn của mạng nơ-ron đối với cửa sổ $\mathbf{X}_t$ thông qua quá trình lan truyền xuôi ngẫu nhiên.

2.4.1 Các độ đo

Trong bài toán phát hiện bất thường chuỗi thời gian, các độ đo truyền thống – chẳng hạn như Precision, Recall, F1 – thường không đánh giá chính xác được tính hiệu quả (performance) của phương pháp do tính chất mất cân bằng nghiêm trọng (severely-imbalanced) giữa số lượng mẫu bình thường (mẫu âm tính) và số lượng mẫu bất thường (mẫu dương tính). Các phương pháp Range-based được đề xuất sau đó để đánh giá hiệu quả phát hiện bất thường theo khoảng (interval anomalies) thường cho ra các kết quả tích cực hơn hiệu quả thật sự của phương pháp. Do đó, các độ đo hiện đại như họ độ đo Volume Under Surface [41] và họ độ đo affiliation [42] đã được đề xuất để khắc phục các hạn chế của những độ đo trước.

Các độ đo họ Volume Under Surface

Trong họ độ đo này, có hai độ đo mà chúng tôi lựa chọn để đánh giá mô hình vì tính phổ biến trong các bài báo gần đây, đó là VUS-PR và VUS-ROC. Trong đó, chúng tôi ưu tiên đánh giá dựa trên VUS-PR hơn vì độ đo ROC cổ điển vốn có tính chính xác kém hơn độ đo PR cổ điển trên dữ liệu mất cân bằng nghiêm trọng.

Cách tính toán của hai độ đo này là như sau:

Giả sử *chuỗi chứa nhãn thật (ground truth series)* và *chuỗi điểm bất thường (point-level anomaly score series)* có độ dài N , lần lượt được ký hiệu là

$$\mathbf{y} = [y_1, \dots, y_N]^\top \in \{0, 1\}^N \quad (2.4)$$

và

$$\mathbf{s} = [s_1, \dots, s_N]^\top \in \mathbb{R}^N. \quad (2.5)$$

Với mỗi ngưỡng bất thường θ , chuỗi điểm bất thường được chuyển

thành chuỗi dự đoán nhị phân (*binary prediction series*)

$$\hat{\mathbf{y}}^{(\theta)} = \left[\hat{y}_1^{(\theta)}, \dots, \hat{y}_N^{(\theta)} \right]^\top, \quad (2.6)$$

trong đó

$$\hat{y}_n^{(\theta)} = \mathbb{I}(s_n \geq \theta), \quad n \in \{1, \dots, N\}. \quad (2.7)$$

Khác với AUC-ROC và AUC-PR cổ điển, VUS không chỉ thay đổi ngưỡng bất thường θ mà còn thay đổi độ dài vùng đệm ℓ quanh mỗi *khoảng bất thường* (*anomaly span*) có nhãn ground-truth. Với mỗi độ dài $\ell \in \{0, 1, \dots, \ell_{\max}\}$, chuỗi ground-truth $\mathbf{y}$ được mở rộng thành chuỗi ground-truth có vùng đệm (*buffered ground-truth series*) $\mathbf{y}^{(\ell)}$. Vùng đệm này cho phép đánh giá một cách linh hoạt hơn các dự đoán xuất hiện hơi sớm hoặc hơi muộn so với khoảng bất thường (*anomaly span*) được gán nhãn ground-truth.

Với mỗi cặp (ℓ, θ) , các đại lượng trên đường cong ROC được tính bằng

$$\text{TPR}^{(\ell)}(\theta) = \text{Recall}^{(\ell)}(\theta) = \frac{\text{TP}^{(\ell)}(\theta)}{\text{TP}^{(\ell)}(\theta) + \text{FN}^{(\ell)}(\theta)}, \quad (2.8)$$

và

$$\text{FPR}^{(\ell)}(\theta) = \frac{\text{FP}^{(\ell)}(\theta)}{\text{FP}^{(\ell)}(\theta) + \text{TN}^{(\ell)}(\theta)}. \quad (2.9)$$

Độ chuẩn xác trên đường cong Precision-Recall được tính bằng

$$\text{Precision}^{(\ell)}(\theta) = \frac{\text{TP}^{(\ell)}(\theta)}{\text{TP}^{(\ell)}(\theta) + \text{FP}^{(\ell)}(\theta)}. \quad (2.10)$$

Khi cố định ℓ , việc thay đổi θ tạo ra một đường cong ROC hoặc Precision-Recall. Khi tiếp tục thay đổi ℓ , nhiều đường cong xếp cạnh nhau tạo thành một bề mặt (*surface*) trong không gian ba chiều. Dựa trên hình ảnh trực quan đó, VUS-ROC được định nghĩa là thể tích đã

được chuẩn hoá dưới bề mặt tạo bởi rất nhiều đường cong ROC:

$$\text{VUS-ROC} = \frac{1}{\ell_{\max}} \int_0^{\ell_{\max}} \text{AUC-ROC}^{(\ell)} d\ell, \quad (2.11)$$

trong đó

$$\text{AUC-ROC}^{(\ell)} = \int \text{TPR}^{(\ell)}(\theta) d\text{FPR}^{(\ell)}(\theta). \quad (2.12)$$

Tương tự, VUS-PR được định nghĩa là thể tích được chuẩn hoá dưới bề mặt rất nhiều đường cong Precision-Recall:

$$\text{VUS-PR} = \frac{1}{\ell_{\max}} \int_0^{\ell_{\max}} \text{AUC-PR}^{(\ell)} d\ell, \quad (2.13)$$

trong đó


$$\text{AUC-PR}^{(\ell)} = \int \text{Precision}^{(\ell)}(\theta) d\text{Recall}^{(\ell)}(\theta). \quad (2.14)$$

Khi tính toán trong thực tế, các tích phân trên được xấp xỉ bằng cách lấy trung bình trên một tập hữu hạn các độ dài vùng đệm ℓ và một tập hữu hạn các ngưỡng bất thường θ . VUS-ROC và VUS-PR có thể được xem là các phiên bản mở rộng của AUC-ROC và AUC-PR theo nghĩa là các độ đo này không phụ thuộc vào một ngưỡng bất thường cố định và ít nhạy (sensitive) hơn với các sai lệch nhỏ giữa các vị trí bất thường ground-truth và các vị trí được dự đoán bởi mô hình.

Chương 3

Phương pháp đề xuất

3.1 Kiến trúc mạng nơ-ron



Hình 3.1: Kiến trúc của mô hình mà chúng tôi đề xuất.

Trong khoá luận này, chúng tôi đề xuất một mạng nơ-ron *học đa tác vụ* (*multi-task learning*) dựa trên hai bộ nhớ (*memory bank*) là *tập nguyên mẫu liên tục* (*continuous prototype bank*) và *tập mã vec-tơ rời rạc* (*discrete codebook*). Tương ứng với tập nguyên mẫu liên tục là *toán*

tử truy vấn liên tục (*continuous query operator*) lấy cảm hứng từ bài nghiên cứu của tác giả Shen [31], và tương ứng với tập nguyên mẫu rời rạc là *toán tử truy vấn rời rạc (discrete query operator)* lấy cảm hứng từ bài nghiên cứu của tác giả Oord [43]. Hai tác vụ học chúng tôi sử dụng trong thiết kế là *tái tạo chuỗi (reconstruction)* và *phân loại đa lớp (multi-class classification)*. Chúng tôi lựa chọn thiết kế học đa tác vụ để giúp biểu diễn ẩn (latent representation) học được bởi bộ mã hoá sẽ có *tính tổng quát hoá (generalization)* cao hơn [44].

3.1.1 Bộ mã hoá chia sẻ chung

Bộ mã hoá được chia sẻ chung giữa hai tác vụ (shared encoder) là một mạng nơ-ron tích chập (convolutional neural networks) sử dụng toán tử tích chập 1 chiều (1D convolution operator). Chi tiết cài đặt của mạng khá đơn giản, chỉ gồm 3 lớp tích chập. Chúng tôi lựa chọn thiết kế đơn giản này là vì muốn phương pháp hướng đến *tính chất không phụ thuộc vào một bộ mã hoá cụ thể (encoder-agnostic)*. Đầu ra của bộ mã hoá chia sẻ chung được gọi là một *ten-xơ trạng thái ẩn (latent tensor)*, chứa bên trong các *vec-tơ trạng thái ẩn (latent vectors)* tương ứng với từng bước thời gian (time-step) trong *cửa sổ đầu vào (input window)*. Chúng tôi ký hiệu ten-xơ trạng thái ẩn như sau:

$$\mathbf{Z}_t = f_{\text{enc}}(\mathbf{X}_t; \boldsymbol{\theta}_{\text{enc}}) \in \mathbb{R}^{T \times H}, \quad (3.1)$$

Trong công thức trên, ten-xơ trạng thái ẩn là một ten-xơ hai chiều hay còn gọi là một ma trận. Nếu ta sử dụng kích thước một lô dữ liệu B từ 2 cửa sổ đầu vào trở lên thì ten-xơ này sẽ là một ten-xơ 3 chiều thuộc không gian ten-xơ $\mathbb{R}^{B \times T \times H}$.

Mỗi vec-tơ trạng thái ẩn được trả về từ mạng mã hoá sẽ được chuẩn hoá độ lớn (normalize) về vec-tơ có độ lớn đơn vị (unit-length vector) hay độ lớn là 1. Thao tác này giúp ánh xạ từng vec-tơ đầu vào ở mỗi bước thời gian lên *bề mặt của một siêu cầu có bán kính đơn vị (surface*

of a unit hypersphere). Bề mặt đó có thể được gọi ngắn gọn hơn là một *đa tạp siêu cầu đơn vị (unit hypersphere manifold)*. Khi lựa chọn *không gian ẩn (latent space)* đầu ra của một bộ mã hoá trong *học tương phản (contrastive learning)* thì đa tạp siêu cầu đơn vị là một lựa chọn phổ biến trong *nguyên cứu thực nghiệm (empirical study)*, theo nguyên cứu của tác giả Wang [45].

Thông qua kiến trúc phân tầng (hierarchical architecture) của mạng nơ-ron tích chập, mỗi vec-tơ ẩn đầu ra của bộ mã hoá sẽ có một vùng tiếp nhận (receptive field) tương ứng, cụ thể hơn là một *vùng tiếp nhận hiệu dụng (effective receptive field)* tương ứng. Bằng cách này, vec-tơ ẩn tại một bước thời gian đầu ra không chỉ chứa thông tin về mẫu hình của bước thời gian tương ứng ở cửa sổ đầu vào, mà còn chứa thông tin của các bước thời gian lân cận ở đầu vào. Điều này cũng đồng nghĩa với việc chúng tôi đang áp dụng *tính cục bộ (locality)* – một *thiên kiến quy nạp (inductive bias)* của mạng nơ-ron tích chập – lên dữ liệu chuỗi thời gian. Tính cục bộ này có nghĩa là mạng nơ-ron tích chập sẽ ưu tiên mô hình hoá mối quan hệ giữa giá trị của các bước thời gian gần nhau.

Trong không gian ẩn mà chúng tôi sử dụng (đa tạp siêu cầu đơn vị), các mẫu hình (patterns) xung quanh một bước thời gian đầu vào sẽ được mã hoá hết vào bên trong *hướng (direction)* của vec-tơ ẩn tương ứng với bước thời gian đó, do *độ lớn (magnitude hay L2-norm)* của mọi vec-tơ đã được chuẩn hoá về 1. Mỗi hướng sẽ tương ứng với các mẫu hình khác nhau. Có những hướng tương ứng với *các mẫu hình bình thường (normal patterns)*, có những hướng tương ứng với *các mẫu hình bất thường (anomalous patterns)*.

3.1.2 Hai bộ nhớ và hai toán tử truy vấn tương ứng

Hai bộ nhớ

Mỗi *bộ nhớ (memory bank)* sẽ chứa một số lượng vec-tơ nguyên mẫu nhất định và được thiết kế để chứa các mẫu hình nhất định.

Theo thiết kế của mạng nơ-ron, mỗi vec-tơ trong tập nguyên mẫu liên tục (continuous prototype bank) sẽ đại diện cho một mẫu hình bình thường. Chúng tôi hình dung một cách trực quan là các mẫu hình bình thường tồn tại như các **cụm điểm (cluster)** trong không gian ẩn (latent space) với mỗi vec-tơ nguyên mẫu liên tục là tâm của một cụm. Về chi tiết cài đặt, chúng tôi sử dụng 32 vec-tơ nguyên mẫu liên tục, đại diện cho 32 tâm cụm bình thường. Chúng tôi sử dụng từ **cụm** là do các vec-tơ nguyên mẫu trong cả 2 bộ nhớ sẽ được khởi tạo bằng thuật toán K-Means [46] sau giai đoạn tiền huấn luyện đa tác vụ của pha tiền huấn luyện ngoại tuyến trong phương pháp.

Trong tập nguyên mẫu rời rạc, mỗi *vec-tơ nguyên mẫu* đại diện cho một mẫu hình của một trong các lớp dữ liệu nhân tạo mà phương pháp sử dụng, bao gồm 1 lớp bình thường (giữ nguyên giá trị gốc) và 11 lớp bất thường nhân tạo (được thêm giá trị nhân tạo). Về chi tiết cài đặt, chúng tôi sử dụng 60 vec-tơ nguyên mẫu rời rạc. Mỗi lớp nhân tạo sẽ có 5 vec-tơ tâm cụm được lưu lại, đại diện cho 5 cụm mẫu hình của mỗi lớp, kể cả lớp bình thường.

Hai toán tử truy vấn tương ứng

Sau khi thu được ten-xơ trạng thái ẩn $\mathbf{Z}_t$ từ bộ mã hoá chung cho hai tác vụ, chúng tôi sử dụng các vec-tơ $\mathbf{z}_{t,i}$ trong ten-xơ này để truy vấn hai bộ nhớ.

Toán tử truy vấn liên tục

Đối với tập nguyên mẫu liên tục, quá trình truy vấn **tất định** có thể được viết thành các phương trình sau:

Ký hiệu tập nguyên mẫu liên tục gồm K_c vec-tơ là

$$\mathbf{P}^{(c)} = [\mathbf{p}_1^{(c)}; \dots; \mathbf{p}_{K_c}^{(c)}] \in \mathbb{R}^{K_c \times H}. \quad (3.2)$$

Xét vec-tơ trạng thái ẩn $\mathbf{z}_{t,i}$, trọng số truy vấn tất định được tính bằng

$$\alpha_{t,i,k}^{(c)} = \frac{\exp\left(\mathbf{z}_{t,i}^\top \mathbf{p}_k^{(c)} / \tau_c\right)}{\sum_{j=1}^{K_c} \exp\left(\mathbf{z}_{t,i}^\top \mathbf{p}_j^{(c)} / \tau_c\right)}, \quad (3.3)$$

trong đó $\tau_c > 0$ là nhiệt độ (temperature), là một siêu tham số (hyper-parameter) cố định trong quá trình huấn luyện mạng.

Vec-tơ được truy xuất từ tập nguyên mẫu liên tục là

$$\tilde{\mathbf{z}}_{t,i}^{(c)} = \sum_{k=1}^{K_c} \alpha_{t,i,k}^{(c)} \mathbf{p}_k^{(c)}. \quad (3.4)$$

Chúng tôi gọi vec-tơ được truy xuất từ tập nguyên mẫu liên tục là *vec-tơ ẩn của nhánh liên tục (continuous-branch latent vector)*. Ngoài ra, độc giả có thể hình dung toán tử truy vấn bên trên khá giống với *toán tử chú ý chéo (cross-attention operator)*, khác ở chỗ toán tử chú ý chéo có thêm phép cộng residual giữa $\mathbf{z}_{t,i}$ và $\tilde{\mathbf{z}}_{t,i}^{(c)}$ [47] [48].

Trong khoá luận này, do hướng đến mục tiêu ước lượng được độ bất định nhận thức (epistemic uncertainty) của mạng nơ-ron, chúng tôi đề xuất phiên bản ngẫu nhiên (stochastic) của toán tử truy vấn liên tục, gọi là *toán tử ngẫu nhiên truy vấn liên tục (stochastic continuous query operator)*. Phiên bản ngẫu nhiên này tương ứng với các phương trình sau:

Ở lần truy vấn ngẫu nhiên thứ m , trước hết chúng tôi lấy mẫu độc lập ngẫu nhiên (sampling) nhiều Gumbel từ cùng một phân phối (i.i.d) như sau:

$$g_{t,i,k}^{(m)} = -\log\left[-\log\left(u_{t,i,k}^{(m)}\right)\right], \quad u_{t,i,k}^{(m)} \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(0, 1). \quad (3.5)$$

Trọng số truy vấn ngẫu nhiên (*stochastic continuous query weights*) ứng với từng nguyên mẫu liên tục được tính bằng hàm Gumbel-Softmax:

$$\alpha_{t,i,k}^{(c,m)} = \frac{\exp\left(\frac{\mathbf{z}_{t,i}^\top \mathbf{p}_k^{(c)} + g_{t,i,k}^{(m)}}{\tau_c}\right)}{\sum_{j=1}^{K_c} \exp\left(\frac{\mathbf{z}_{t,i}^\top \mathbf{p}_j^{(c)} + g_{t,i,j}^{(m)}}{\tau_c}\right)}. \quad (3.6)$$

Khi đó, vec-tơ được truy xuất ở lần thứ m là

$$\tilde{\mathbf{z}}_{t,i}^{(c,m)} = \sum_{k=1}^{K_c} \alpha_{t,i,k}^{(c,m)} \mathbf{p}_k^{(c)}. \quad (3.7)$$

Toán tử truy vấn rời rạc

Đối với tập nguyên mẫu rời rạc thì toán tử truy vấn tắt định có thể được viết thành các phương trình sau:

Ký hiệu tập nguyên mẫu rời rạc gồm K_d vec-tơ là

$$\mathbf{P}^{(d)} = [\mathbf{p}_1^{(d)}; \dots; \mathbf{p}_{K_d}^{(d)}] \in \mathbb{R}^{K_d \times H}. \quad (3.8)$$

Xét vec-tơ trạng thái ẩn $\mathbf{z}_{t,i}$, khoảng cách đến nguyên mẫu rời rạc thứ k được tính bằng

$$\begin{aligned} d_{t,i,k}^{(d)} &= \left\| \mathbf{z}_{t,i} - \mathbf{p}_k^{(d)} \right\|_2^2 \\ &= 2 \left(1 - \cos \left(\mathbf{z}_{t,i}, \mathbf{p}_k^{(d)} \right) \right). \end{aligned} \quad (3.9)$$

Ở phương trình trên, dấu bằng thứ hai là một tính chất hữu ích của việc chuẩn hoá độ lớn các vec-tơ ẩn về độ lớn đơn vị.

Tập chỉ số của K_{top} nguyên mẫu gần nhất được xác định bởi

$$\mathcal{I}_{t,i}^{(d)} = \text{TopKMin}_{k \in \{1, \dots, K_d\}} \left(d_{t,i,k}^{(d)}; K_{\text{top}} \right), \quad (3.10)$$

trong đó TopKMin trả về chỉ số của K_{top} giá trị nhỏ nhất. Trong cài đặt của chúng tôi, $K_{\text{top}} = 3$.

Trọng số ứng với các nguyên mẫu được chọn là

$$\alpha_{t,i,k}^{(d)} = \begin{cases} \frac{\exp \left(-d_{t,i,k}^{(d)} / \tau_d \right)}{\sum_{j \in \mathcal{I}_{t,i}^{(d)}} \exp \left(-d_{t,i,j}^{(d)} / \tau_d \right)}, & k \in \mathcal{I}_{t,i}^{(d)}, \\ 0, & k \notin \mathcal{I}_{t,i}^{(d)}. \end{cases} \quad (3.11)$$

Vec-tơ ẩn của nhánh rời rạc (discrete-branch latent vector) được tính bằng

$$\tilde{\mathbf{z}}_{t,i}^{(d)} = \sum_{k \in \mathcal{I}_{t,i}^{(d)}} \alpha_{t,i,k}^{(d)} \mathbf{p}_k^{(d)}. \quad (3.12)$$

Phiên bản ngẫu nhiên của toán tử truy vấn rời rạc, còn gọi là *toán tử truy vấn ngẫu nhiên rời rạc (stochastic discrete query operator)*, có thể được trình bày như sau:

Ở lần truy vấn ngẫu nhiên thứ m , chúng tôi lấy mẫu độc lập ngẫu nhiên nhiều Gumbel từ cùng một phân phối

$$g_{t,i,k}^{(d,m)} = -\log \left[-\log \left(u_{t,i,k}^{(d,m)} \right) \right], \quad u_{t,i,k}^{(d,m)} \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(0, 1). \quad (3.13)$$

Điểm truy vấn (*stochastic discrete query score*) sau khi thêm nhiễu được tính như sau:

$$q_{t,i,k}^{(d,m)} = \frac{-d_{t,i,k}^{(d)} + g_{t,i,k}^{(d,m)}}{\tau_d}, \quad (3.14)$$

trong đó $\tau_d > 0$ là nhiệt độ của toán tử truy vấn rời rạc.

Tập chỉ số của K_{top} nguyên mẫu được chọn ở lần truy vấn thứ m là

$$\mathcal{I}_{t,i}^{(d,m)} = \text{TopKMax}_{k \in \{1, \dots, K_d\}} \left(q_{t,i,k}^{(d,m)}; K_{\text{top}} \right). \quad (3.15)$$

Trọng số truy vấn ngẫu nhiên (*stochastic discrete query*) được tính bằng

$$\alpha_{t,i,k}^{(d,m)} = \begin{cases} \frac{\exp \left(q_{t,i,k}^{(d,m)} \right)}{\sum_{j \in \mathcal{I}_{t,i}^{(d,m)}} \exp \left(q_{t,i,j}^{(d,m)} \right)}, & k \in \mathcal{I}_{t,i}^{(d,m)}, \\ 0, & k \notin \mathcal{I}_{t,i}^{(d,m)}. \end{cases} \quad (3.16)$$

Khi đó, vec-tơ được truy xuất ở lần thứ m là

$$\tilde{\mathbf{z}}_{t,i}^{(d,m)} = \sum_{k \in \mathcal{I}_{t,i}^{(d,m)}} \alpha_{t,i,k}^{(d,m)} \mathbf{p}_k^{(d)}. \quad (3.17)$$

Như vậy, ten-xơ ẩn của nhánh rời rạc (discrete-branch latent tensor) là tập hợp các vec-tơ ẩn của nhánh đó, ký hiệu

$$\tilde{\mathbf{Z}}_t^{(d,m)} = \left[\tilde{\mathbf{z}}_{t,1}^{(d,m)}; \dots; \tilde{\mathbf{z}}_{t,T}^{(d,m)} \right] \in \mathbf{R}^{T \times H}. \quad (3.18)$$

Tương tự đối với nhánh liên tục, ký hiệu

$$\tilde{\mathbf{Z}}_t^{(c,m)} = \left[\tilde{\mathbf{z}}_{t,1}^{(c,m)}; \dots; \tilde{\mathbf{z}}_{t,T}^{(c,m)} \right] \in \mathbf{R}^{T \times H}. \quad (3.19)$$

Như vậy, ten-xơ ẩn của nhánh rời rạc (discrete-branch latent tensor) là tập hợp các vec-tơ ẩn của nhánh đó, ký hiệu

$$\tilde{\mathbf{Z}}_t^{(d,m)} = \left[\tilde{\mathbf{z}}_{t,1}^{(d,m)}; \dots; \tilde{\mathbf{z}}_{t,T}^{(d,m)} \right] \in \mathbf{R}^{T \times H}. \quad (3.20)$$

Tương tự đối với nhánh liên tục, ký hiệu


$$\tilde{\mathbf{Z}}_t^{(c,m)} = \left[\tilde{\mathbf{z}}_{t,1}^{(c,m)}; \dots; \tilde{\mathbf{z}}_{t,T}^{(c,m)} \right] \in \mathbf{R}^{T \times H}. \quad (3.21)$$

3.2 Quy trình tiền huấn luyện và hàm mất mát tương ứng

Quy trình tiền huấn luyện được chúng tôi gọi là ***pha*** tiền huấn luyện ngoại tuyến (*offline pre-training phase*), phân biệt với ***pha*** thích ứng khi kiểm thử trực tuyến (*online test-time adaptation phase*). Luồng tổng quan của pha này được trình bày trong Thuật toán 1.

Pha tiền huấn luyện ngoại tuyến sẽ bao gồm 2 **giai đoạn (stage)** là **giai đoạn** học biểu diễn đa nhiệm (*offline multi-task learning stage*) và **giai đoạn** tinh chỉnh bộ kết hợp (*fusion head fine-tuning stage*). Chúng tôi sẽ gọi hai giai đoạn này là giai đoạn A và giai đoạn B.

Trong giai đoạn A, để tập trung học biểu diễn đa nhiệm, chúng tôi chỉ huấn luyện mạng mã hoá (*encoder network*) và hai mạng dự đoán (*prediction heads*) tương ứng với hai tác vụ (Xem hình 3.2). Chúng tôi chưa khởi tạo hai bộ nhớ trong giai đoạn này và do đó, chưa cần thêm các mạng kết hợp (*fusion networks*) tương ứng. Mạng mã hoá là một mạng nơ-ron tích chập 1 chiều (*1-dimensional convolutional neural network*) như đã trình bày ở Mục 3.1.



Hình 3.2: Kiến trúc mô hình trong giai đoạn A của pha ngoại tuyến.

Trong giai đoạn học biểu diễn đa nhiệm, chúng tôi sử dụng 3 hàm mất mát chính: một hàm cho tác vụ tái tạo chuỗi, một hàm cho tác vụ phân loại đa lớp và một hàm để học tương phản ở cấp độ điểm thời gian (*point-level contrastive loss*). Lí do chúng tôi sử dụng hàm tương phản ở cấp độ điểm thời gian là để phân tách rõ ràng hơn các vec-tơ mẫu hình bình thường và các vec-tơ mẫu hình bất thường trong không gian ẩn mà chúng tôi đã lựa chọn (*đa tập siêu cầu đơn vị*).


Quá trình *lan truyền xuôi* (*forward-propagation*) tương ứng với các phương trình sau:

Ký hiệu một *cửa sổ sạch* (*clean window*) đến từ *chuỗi huấn luyện gốc* (*original train series*) là $\mathbf{X}_t^{(0)}$. Từ cùng cửa sổ này, chúng tôi tạo ra


một phiên bản bất thường nhân tạo (*synthetic anomalous view*) thuộc lớp $a_t \in \{1, \dots, 11\}$:

$$\mathbf{X}_t^{(a_t)} = (\mathbf{1} - \mathbf{M}_t) \odot \mathbf{X}_t^{(0)} + \mathbf{M}_t \odot \mathcal{A}_{a_t}(\mathbf{X}_t^{(0)}; \boldsymbol{\xi}_t), \quad (3.22)$$

trong đó $\mathbf{M}_t$ là vec-tơ mặt nạ xác định các *bước thời gian* (*time-step*) được tiêm bất thường, $\mathcal{A}_{a_t}$ là *hàm biến đổi* (*transformation function*) tương ứng với lớp bất thường a_t , và $\boldsymbol{\xi}_t$ chứa các tham số ngẫu nhiên của *hàm biến đổi*. Những vị trí có $\mathbf{M}_t = 0$ được giữ nguyên giá trị gốc từ cửa sổ sạch. Trong khóa luận này, chúng tôi sử dụng 11 lớp bất thường nhân tạo sau: tăng đột ngột (spike), lật ngang (flip), tăng nhịp độ (speedup), nhiễu (noise), cắt theo ngưỡng (cutoff), trung bình hóa (average), co giãn biên độ (scale), dao động kiểu trôi dạt (wander), bất thường theo ngữ cảnh (contextual), lật dọc (upsidedown) và bất thường hỗn hợp (mixture). Tương ứng với 11 lớp bất thường nhân tạo sẽ có 11 hàm biến đổi (*transformation functions*). 11 lớp bất thường nhân tạo này được minh họa trong Hình 3.3 và Hình 3.4.



Hình 3.3: Các lớp bất thường nhân tạo từ 0 đến 5.



Hình 3.4: Các lớp bất thường nhân tạo từ 6 đến 11.

Hai phiên bản của cùng một cửa sổ được đưa qua cùng một bộ mã hoá:

$$\mathbf{Z}_t^{(0)} = f_{\text{enc}} \left(\mathbf{X}_t^{(0)}; \boldsymbol{\theta}_{\text{enc}} \right), \quad (3.23)$$

$$\mathbf{Z}_t^{(a_t)} = f_{\text{enc}} \left(\mathbf{X}_t^{(a_t)}; \boldsymbol{\theta}_{\text{enc}} \right). \quad (3.24)$$

Đối với tác vụ tái tạo chuỗi, cửa sổ sạch được tái tạo bằng

$$\hat{\mathbf{X}}_t^{(0)} = f_{\text{rec}} \left(\mathbf{Z}_t^{(0)}; \boldsymbol{\theta}_{\text{rec}} \right). \quad (3.25)$$

Đối với tác vụ phân loại đa lớp, xác suất dự đoán được tính cho cả cửa sổ sạch và cửa sổ bất thường nhân tạo:

$$\hat{\mathbf{y}}_t^{(v)} = \text{softmax} \left[f_{\text{cls}} \left(\text{Pool} \left(\mathbf{Z}_t^{(v)} \right); \boldsymbol{\theta}_{\text{cls}} \right) \right], \quad v \in \{0, a_t\}, \quad (3.26)$$

trong đó $v = 0$ biểu thị lớp sạch và $v = a_t$ biểu thị lớp bất thường nhân tạo. Trong đó hàm Pool thường là hàm trung bình theo từng biến của vec-tơ ẩn.

Trong quá trình học tương phản ở cấp độ điểm thời gian, mỗi vec-tơ

$\mathbf{z}_{t,i}^{(0)}$ của cửa sổ sạch được sử dụng làm *điểm neo (anchor point)*. Vec-tơ tương ứng $\mathbf{z}_{t,i}^{(a_t)}$ là *điểm dương tương ứng (positive point)* nếu vị trí i không được tiêm bất thường, và là *điểm đối tượng tương ứng (negative point)* nếu vị trí này được tiêm bất thường:

$$\mathbf{z}_{t,i}^{(a_t)} \in \begin{cases} \mathcal{P}(\mathbf{z}_{t,i}^{(0)}), & \mathbf{M}_{t,i} = 0, \\ \mathcal{N}(\mathbf{z}_{t,i}^{(0)}), & \mathbf{M}_{t,i} = 1. \end{cases} \quad (3.27)$$

Cuối cùng, các hàm mất mát được tính toán theo các phương trình sau. Hàm mất mát tái tạo chuỗi là

$$\mathcal{L}_{\text{rec}} = \frac{1}{TC} \left\| \mathbf{X}_t^{(0)} - \widehat{\mathbf{X}}_t^{(0)} \right\|_F^2. \quad (3.28)$$

Trong đó, T là số bước độ dài của cửa sổ, còn C là số biến của chuỗi thời gian.

Hàm mất mát phân loại đa lớp là

$$\mathcal{L}_{\text{cls}} = -\frac{1}{2} \sum_{v \in \{0, a_t\}} \sum_{r=0}^{11} y_{t,r}^{(v)} \log \hat{y}_{t,r}^{(v)}. \quad (3.29)$$

Hàm mất mát tương phản ở cấp độ điểm thời gian là

$$\begin{aligned} \mathcal{L}_{\text{con}} = -\frac{1}{|\mathcal{Q}|} \sum_{\mathbf{z}_q \in \mathcal{Q}} \log & \left[\sum_{\mathbf{z}_p \in \mathcal{P}(\mathbf{z}_q)} \exp \left(\frac{\cos(\mathbf{z}_q, \mathbf{z}_p)}{\tau_{\text{con}}} \right) \right. \\ & \left. / \left(\sum_{\mathbf{z}_p \in \mathcal{P}(\mathbf{z}_q)} \exp \left(\frac{\cos(\mathbf{z}_q, \mathbf{z}_p)}{\tau_{\text{con}}} \right) \right. \right. \\ & \left. \left. + \sum_{\mathbf{z}_n \in \mathcal{N}(\mathbf{z}_q)} \exp \left(\frac{\cos(\mathbf{z}_q, \mathbf{z}_n)}{\tau_{\text{con}}} \right) \right) \right]. \end{aligned} \quad (3.30)$$

trong đó $\mathcal{Q}$ là tập các *điểm neo (anchor point)*, $\mathcal{P}(\mathbf{z}_q)$ là tập các *điểm dương tương ứng (positive point)* và $\mathcal{N}(\mathbf{z}_q)$ là tập các *điểm đối tượng tương ứng*

(*negative point*) của điểm neo $\mathbf{z}_q$.


Hàm mất mát tổng (*total loss*) của giai đoạn học biểu diễn đa nhiệm là

$$\mathcal{L}_{\text{multi}} = \lambda_{\text{rec}}\mathcal{L}_{\text{rec}} + \lambda_{\text{cls}}\mathcal{L}_{\text{cls}} + \lambda_{\text{con}}\mathcal{L}_{\text{con}}. \quad (3.31)$$

Đến đây, chúng tôi có thể tính toán gradient của hàm mất mát theo từng tham số trong mạng mã hoá (encoder network), hai mạng dự đoán (prediction networks) sử dụng thuật toán lan truyền ngược (backpropagation) [49]. Và sử dụng các gradient để cập nhật từng tham số theo các *thuật toán tối ưu ngẫu nhiên (stochastic optimization algorithms)* như Stochastic Gradient Descent đơn giản [50] hoặc các phiên bản hiện đại hơn như Adam [51], AdamW [52].

Sau khi huấn luyện xong giai đoạn A, chúng tôi kỳ vọng thu được mạng mã hoá đã học được biểu diễn đa nhiệm và dùng mạng này để khởi tạo hai bộ nhớ. Chúng tôi chọn ra một vài lô dữ liệu trong tập huấn luyện, sau đó tiêm bất thường vào các cửa sổ trong tập này sao cho tỉ lệ giữa 12 lớp, gồm 1 lớp bình thường và 11 lớp bất thường nhân tạo, là bằng nhau. Đối với tập nguyên mẫu liên tục, chúng tôi lọc ra tất cả điểm thời gian bình thường trong các lô được chọn rồi chạy thuật toán K-Means để chọn ra 32 vec-tơ đại diện cho 32 cụm mẫu hình bình thường. Đối với tập nguyên mẫu rời rạc, với mỗi lớp trong 12 lớp, chúng tôi cũng lọc ra các điểm thời gian thuộc lớp đó rồi chạy thuật toán K-Means để chọn ra 5 vec-tơ đại diện cho mỗi lớp trong 12 lớp. Sau khi khởi tạo xong thì chúng tôi cũng **đóng băng (freeze)** mạng mã hoá và 2 bộ nhớ để đảm bảo mạng mã hoá và 2 bộ nhớ đến từ cùng một *xấp xỉ hàm (function approximator)* đã học được. Ở đây, **đóng băng** một tham số nghĩa là không tính toán gradient của hàm mất mát theo tham số đó.

Tiếp theo chính là giai đoạn B: tinh chỉnh các mạng tổng hợp (fusion networks). Kiến trúc mạng nơ-ron của giai đoạn này được minh hoạ ở Hình 3.5.



Hình 3.5: Kiến trúc mô hình trong giai đoạn B của pha ngoại tuyến. Tham số của các mô-đun nằm trong vùng màu xanh dương nhạt sẽ bị đóng băng. Tham số của các mô-đun nằm trong vùng màu đỏ nhạt sẽ được tính gradient.

Gọi $\tilde{\mathbf{Z}}_t^{(c,m)}$ và $\tilde{\mathbf{Z}}_t^{(d,m)}$ là hai ten-xơ đầu ra tương ứng với nhánh liên tục và nhánh rời rạc. Quá trình lan truyền xuôi tính từ các mạng tổng hợp (fusion networks) diễn ra như sau.

Trước hết, ten-xơ trạng thái ẩn ban đầu và đầu ra của hai nhánh được ghép lại với mục đích là để mạng tổng hợp tiếp cận được ten-xơ ẩn gốc:

$$\mathbf{Z}_t^{(\text{cat},m)} = \text{Concat} \left[\mathbf{Z}_t, \tilde{\mathbf{Z}}_t^{(c,m)}, \tilde{\mathbf{Z}}_t^{(d,m)} \right] \in \mathbb{R}^{T \times 3H}. \quad (3.32)$$

Hai mạng tổng hợp tương ứng với hai tác vụ tạo ra hai ten-xơ trạng thái ẩn:

$$\mathbf{H}_t^{(\text{rec},m)} = f_{\text{fus}}^{(\text{rec})} \left(\mathbf{Z}_t^{(\text{cat},m)}; \boldsymbol{\theta}_{\text{fus}}^{(\text{rec})} \right), \quad (3.33)$$

$$\mathbf{H}_t^{(\text{cls},m)} = f_{\text{fus}}^{(\text{cls})} \left(\mathbf{Z}_t^{(\text{cat},m)}; \boldsymbol{\theta}_{\text{fus}}^{(\text{cls})} \right). \quad (3.34)$$

Đầu tái tạo chuỗi tạo ra cửa sổ tái tạo:

$$\hat{\mathbf{X}}_t^{(m)} = f_{\text{rec}} \left(\mathbf{H}_t^{(\text{rec},m)}; \boldsymbol{\theta}_{\text{rec}} \right). \quad (3.35)$$

Đầu phân loại đa lớp tạo ra xác suất dự đoán:

$$\hat{\mathbf{y}}_t^{(m)} = \text{softmax} \left[f_{\text{cls}} \left(\text{Pool} \left(\mathbf{H}_t^{(\text{cls},m)} \right); \boldsymbol{\theta}_{\text{cls}} \right) \right]. \quad (3.36)$$

Trong giai đoạn B, chúng tôi sử dụng hàm mất mát tái tạo

$$\mathcal{L}_{\text{rec}}^{(B)} = \frac{1}{TC} \left\| \mathbf{X}_t - \hat{\mathbf{X}}_t^{(m)} \right\|_F^2 \quad (3.37)$$

và hàm mất mát phân loại đa lớp

$$\mathcal{L}_{\text{cls}}^{(B)} = - \sum_{r=0}^{11} y_{t,r} \log \hat{y}_{t,r}^{(m)}. \quad (3.38)$$

Hàm mất mát tổng của giai đoạn tinh chỉnh các mạng tổng hợp là

$$\mathcal{L}_B = \lambda_{\text{rec}} \mathcal{L}_{\text{rec}}^{(B)} + \lambda_{\text{cls}} \mathcal{L}_{\text{cls}}^{(B)}. \quad (3.39)$$

Trong giai đoạn này, mạng mã hoá, tập nguyên mẫu liên tục và tập

nguyên mẫu rời rạc đều được đồng bằng. Gradient chỉ được sử dụng để cập nhật hai mạng tổng hợp và hai mạng dự đoán.

Sau khi huấn luyện xong hai giai đoạn A và B, chúng tôi tính toán ngưỡng bất thường (anomaly threshold) từ tập xác thực (validation set). Điểm bất thường (anomaly score) được tính ở cấp độ điểm dữ liệu (point-level) sử dụng hàm *tổng sai số bình phương* (*mean squared errors - MSE*) – tương ứng với *độ lệch tái tạo* – trên từng điểm dữ liệu trong từng cửa sổ xác thực (validation window). Trong thí nghiệm, chúng tôi chia chuỗi xác thực thành các cửa sổ không chồng lấp (non-overlapping window) nên sau khi tính toán xong MSE cho từng điểm trong từng cửa sổ, chúng tôi ghép các danh sách MSE này lại theo thứ tự thời gian của chuỗi gốc và tính toán các độ đo VUS-PR [41], affiliation F1 [42] và VUS-ROC [41] dựa trên chuỗi tổng hợp này.

Thuật toán 1: Pha tiền huấn luyện ngoại tuyến

Require: $\mathcal{D}_{\text{train}}$, $\mathcal{D}_{\text{val}}$, bộ cấu hình Ω

Ensure: Checkpoint tốt nhất Θ^*

```

1:  $\mathcal{P} \leftarrow \{A, B\}$ 
2: for  $p \in \mathcal{P}$  do
3:   Khởi tạo bộ cấu hình đúng giai đoạn  $\Omega_p$ 
4:   if  $p = B$  then
5:     Đọc checkpoint tốt nhất của Stage A
6:     Khởi tạo 2 bộ nhớ từ  $\mathcal{D}_{\text{train}}$ 
7:   for mỗi epoch do
8:     for mỗi lô dữ liệu  $(X, Y, M)$  trong  $\mathcal{D}_{\text{train}}$  do
9:       Lan truyền xuôi
10:      Tính toán  $\mathcal{L}_{\text{rec}}$  và  $\mathcal{L}_{\text{cls}}$ 
11:      Tính toán các hàm mất mát bổ trợ khác
12:      Tính toán hàm mất mát tổng  $\mathcal{L}$ 
13:      Cập nhật các tham số học được (learnable)
14:     Đánh giá trên  $\mathcal{D}_{\text{val}}$ 
15:     Lưu lại checkpoint nếu như hiệu quả đánh giá có cải thiện.
16: return  $\Theta^*$ 

```

3.3 Quy trình thích ứng trực tuyến trên dòng dữ liệu và hàm mất mát tương ứng

Trong pha thích ứng trực tuyến khi kiểm thử trên dòng dữ liệu (streaming time-series), mục tiêu của chúng tôi là phát hiện ra được các mẫu hình bình thường mới và thích ứng mạng nơ-ron trên các mẫu hình đó ngay trên dòng trực tuyến (online stream). Đồng thời, đảm bảo không gian ẩn đầu ra của mạng nơ-ron sau khi được thích ứng không quá khác so với không gian ẩn đầu ra của mạng nơ-ron gốc. Kiến trúc trong giai đoạn này được minh hoạ trong Hình 3.6. Thuật toán 2 bên dưới trình bày luồng tổng quan của pha thích ứng trực tuyến.

Thuật toán 2: Pha thích ứng trực tuyến


Require: Dòng dữ liệu $\mathcal{S}$, checkpoint từ pha ngoại tuyến Θ^* , bộ cấu hình Ω

Ensure: Mô hình trong pha trực tuyến Θ_{online}

- 1: $\Theta_{\text{online}} \leftarrow \Theta^*$
 - 2: Khởi tạo bộ đệm xác minh $\mathcal{B}_{\text{ver}}$
 - 3: Khởi tạo bộ đệm Time-to-Live $\mathcal{B}_{\text{ttl}}$
 - 4: **for** mỗi cửa sổ X_t trên $\mathcal{S}$ **do**
 - 5: Tính điểm bất thường s_t
 - 6: decision, $M_t \leftarrow \text{RouteAndVerifyPNN}(X_t, s_t, \mathcal{B}_{\text{ver}})$
 - 7: Cập nhật các bộ đệm dựa trên decision
 - 8: **if** $M_t \neq \emptyset$ **then**
 - 9: Cập nhật Θ_{online} bằng các điểm thời gian trong M_t
 - 10: Lưu dự đoán và các thống kê khác của X_t
 - 11: **return** Θ_{online}
-

Thuật toán 3: Phân luồng và xác thực pseudo-new-normality

```
1: procedure ROUTEANDVERIFY PNN( $X_t, s_t, \mathcal{B}_{\text{ver}}$ )
2:   if  $s_t < \delta_{\text{normal}}$  then
3:     decision  $\leftarrow$  normal
4:      $M_t \leftarrow \emptyset$ 
5:   else if  $s_t > \delta_{\text{anomaly}}$  then
6:     decision  $\leftarrow$  anomaly
7:      $M_t \leftarrow \emptyset$ 
8:   else
9:     decision  $\leftarrow$  gray-zone
10:    Đưa  $X_t$  vào  $\mathcal{B}_{\text{ver}}$ 
11:     $M_t \leftarrow \emptyset$ 
12:    if  $\mathcal{B}_{\text{ver}}$  chứa đủ số cửa sổ then
13:      Loại bỏ các time-point nằm trong cụm bất thường đã biết
14:      Tính toán chữ ký của các time-point còn lại
15:      Xác định các chữ ký lặp lại qua nhiều cửa sổ
16:      Tạo vec-tơ mặt nạ nhị phân cho pseudo-new-normality  $M_t$ 
17:      if  $M_t \neq \emptyset$  then
18:        decision  $\leftarrow$  pseudo-new-normal
19:      else
20:        decision  $\leftarrow$  unresolved
21:    return decision,  $M_t$ 
```



Hình 3.6: Kiến trúc mô hình trong pha trực tuyến. Tham số của các mô-đun nằm trong vùng màu xanh dương nhạt sẽ bị đóng băng. Tham số của các mô-đun nằm trong vùng màu đỏ nhạt sẽ được tính gradient.

3.3.1 Nhánh biểu diễn nguồn và bộ ánh xạ trực tuyến

Từ checkpoint của giai đoạn B, chúng tôi đóng băng mạng mã hoá, hai bộ nhớ, hai mạng tổng hợp và hai mạng dự đoán. Xét cửa sổ trực tuyến (online window) $\mathbf{X}_t$ mà mô hình nhận được tại bước thời gian t , *ten-xơ trạng thái ẩn của nhánh nguồn (source latent tensor)* được tính một lần:

$$\mathbf{Z}_t^{(\text{src})} = f_{\text{enc}}(\mathbf{X}_t; \boldsymbol{\theta}_{\text{enc}}). \quad (3.40)$$

Ten-xơ trạng thái ẩn trực tuyến (online latent tensor) là đầu ra của một mạng perceptron đa lớp (multi-layer perceptron - MLP) được khởi tạo xấp xỉ như một *hàm định danh (identity function)*:

$$\mathbf{Z}_t^{(\text{on})} = g_{\text{proj}} \left(\mathbf{Z}_t^{(\text{src})}; \boldsymbol{\phi} \right). \quad (3.41)$$

Trong pha thích ứng khi kiểm thử trực tuyến, chỉ có tham số $\boldsymbol{\phi}$ của mạng multi-layer perceptron được tính toán gradient và cập nhật. Tham số của các mô-đun còn lại của mạng trực tuyến đều sẽ bị đóng băng.

3.3.2 Ngưỡng bất thường trực tuyến và cơ chế phân luồng cửa sổ trực tuyến

Tại bước thời gian t , mạng nơ-ron nhận đầu vào là một cửa sổ trực tuyến (online window) $\mathbf{X}_t \in \mathbb{R}^{T \times C}$. Ở lần lan truyền xuôi ngẫu nhiên (stochastic forward-propagation) thứ m , độ lệch tái tạo của điểm thời gian thứ i trong cửa sổ được tính bằng phương trình

$$s_{t,i}^{(m)} = \frac{1}{C} \left\| \mathbf{x}_{t,i} - \widehat{\mathbf{x}}_{t,i}^{(m)} \right\|_2^2. \quad (3.42)$$

Sau M lần lan truyền xuôi ngẫu nhiên, độ lệch tái tạo trung bình được tính bằng phương trình

$$\bar{s}_{t,i} = \frac{1}{M} \sum_{m=1}^M s_{t,i}^{(m)}. \quad (3.43)$$

Do các cửa sổ trực tuyến được hình thành theo cơ chế cửa sổ trượt (sliding window), một điểm thời gian cụ thể có thể sẽ xuất hiện trong nhiều cửa sổ trượt liên tiếp nhau. Để *điểm bất thường (anomaly score)* phản ánh những thông tin gần nhất và đồng thời giữ được thông tin quá khứ, chúng tôi sử dụng kỹ thuật làm trơn (smoothing) các độ lệch tái tạo của cùng một điểm thời gian bằng phép tính trung bình trượt hàm

mũ (*exponentially weighted moving average – EWMA*):

$$\tilde{s}_n^{(r)} = \rho \bar{s}_n^{(r)} + (1 - \rho) \tilde{s}_n^{(r-1)}, \quad (3.44)$$

trong đó n là *chỉ số tuyệt đối* (*absolute index* hay *global index*) của điểm thời gian trên toàn bộ dòng dữ liệu, r là số lần điểm này xuất hiện trong các cửa sổ đã được mạng ra quyết định và $\rho = 0.9$ là chi tiết cài đặt cụ thể mà chúng tôi sử dụng. Ở lần xuất hiện đầu tiên của một điểm thời gian (time-point), chúng tôi đặt

$$\tilde{s}_n^{(1)} = \bar{s}_n^{(1)}. \quad (3.45)$$

Một điểm thời gian được dự đoán là bất thường nếu

$$\hat{a}_n = \mathbb{I}(\tilde{s}_n > T_{\text{point}}), \quad (3.46)$$

trong đó T_{point} là ngưỡng bất thường được *hiệu chỉnh* (*calibrated*) từ *chuỗi xác thực gốc* (*clean validation series* hay *original validation series*).

Độ lệch tái tạo ở cấp độ cửa sổ (*window-level reconstruction error*) được tính bằng trung bình của các điểm bất thường đã được làm trơn (*smoothed anomaly scores*) bên trong một cửa sổ:

$$S_t^{(\text{input})} = \frac{1}{T} \sum_{i=1}^T \tilde{s}_{t,i}. \quad (3.47)$$

Ngoài ra, chúng tôi tính toán thêm khoảng cách từ mỗi vec-tơ ẩn trực tuyến (online latent vector) đến vec-tơ nguyên mẫu liên tục (continuous prototype) gần với vec-tơ đó nhất để biết được vec-tơ ẩn trực tuyến gần với cụm mẫu hình bình thường nào nhất:

$$S_t^{(\text{latent})} = \frac{1}{T} \sum_{i=1}^T \min_{k \in \{1, \dots, K_c\}} \left\| \mathbf{z}_{t,i}^{(\text{on})} - \mathbf{p}_k^{(c)} \right\|_2^2. \quad (3.48)$$

Gọi B_{win} là ngưỡng của độ lệch tái tạo cửa sổ (window-level reconstruction error), còn $A_{\text{win}}^{(\text{low})}$ và $A_{\text{win}}^{(\text{high})}$ lần lượt là ngưỡng dưới và ngưỡng trên của các khoảng cách trong không gian ẩn. Một cửa sổ trực tuyến được phân vào các luồng theo *quy tắc tam phân (triage)* sau đây:

$$\text{Triage}(\mathbf{X}_t) = \begin{cases} \text{normal}, & S_t^{(\text{input})} \leq B_{\text{win}}, \\ \text{hard-old-normality}, & \begin{aligned} & S_t^{(\text{input})} > B_{\text{win}} \\ & \wedge S_t^{(\text{latent})} \leq A_{\text{win}}^{(\text{low})}, \end{aligned} \\ \text{gray zone}, & \begin{aligned} & S_t^{(\text{input})} > B_{\text{win}} \\ & \wedge A_{\text{win}}^{(\text{low})} < S_t^{(\text{latent})} \leq A_{\text{win}}^{(\text{high})}, \end{aligned} \\ \text{strong anomaly}, & \begin{aligned} & S_t^{(\text{input})} > B_{\text{win}} \\ & \wedge S_t^{(\text{latent})} > A_{\text{win}}^{(\text{high})}. \end{aligned} \end{cases} \quad (3.49)$$

Trong đó, “**normal**” nghĩa là cửa sổ trực tuyến đó được mạng dự đoán là bình thường. “**hard-old-normality**” nghĩa là cửa sổ đó có chứa mẫu hình bình thường gần với các mẫu hình trong tập huấn luyện nhưng mạng lại chưa học được tốt, hay nói cách khác, đó là các mẫu hình *bình thường khó*. “**strong anomaly**” nghĩa là cửa sổ đó có khả năng cao là bất thường vì vừa có điểm bất thường cao hơn ngưỡng và có khoảng cách (trong không gian ẩn) là xa so với các mẫu hình bình thường được lưu lại trong tập nguyên mẫu liên tục (continuous prototype). Các cửa sổ còn lại được phân vào luồng “**gray zone**” (vùng xám) để tính toán thêm. Chúng tôi gọi là quy tắc tam phân (triage) do chỉ quan tâm đến 3 trường hợp mà độ lệch tái tạo cửa sổ (window-level reconstruction error) lớn hơn B_{win} .

Các cửa sổ *normal* sẽ không được sử dụng để thích ứng mạng. Các cửa sổ *hard-old-normality* được sử dụng để cập nhật bộ ánh xạ perceptron đa lớp (MLP projector), và các cửa sổ của luồng *gray zone* được thêm vào bộ đệm xác minh (*verification buffer*). Các cửa sổ *strong anomaly* cũng không được dùng để thích ứng mạng nhằm hạn chế nguy cơ mô hình

vô tình học phải các mẫu hình bất thường. Toàn bộ các ngưỡng T_{point} , B_{win} , $A_{\text{win}}^{(\text{low})}$ và $A_{\text{win}}^{(\text{high})}$ đều được hiệu chỉnh từ chuỗi *original validation*. Chúng tôi không sử dụng nhãn của *chuỗi kiểm thử (test series)* để đảm bảo không vi phạm hiện tượng rò rỉ dữ liệu (*data leakage*).

3.3.3 Thích ứng mạng với các mẫu hình bình thường khó

Một cửa sổ trực tuyến $\mathbf{X}_t$ được xác định là *bất thường khó* khi độ lệch tái tạo của cửa sổ vượt quá ngưỡng B_{win} nhưng các vec-tơ ẩn trực tuyến (online latent vectors) của cửa sổ đó vẫn nằm gần tập nguyên mẫu liên tục:

$$S_t^{(\text{input})} > B_{\text{win}} \quad \wedge \quad S_t^{(\text{latent})} \leq A_{\text{win}}^{(\text{low})}. \quad (3.50)$$

Như đã diễn giải ở phần 3.3.2, các cửa sổ trong luồng này có chứa các mẫu hình gần với những mẫu hình bình thường từ tập huấn luyện được lưu lại trong tập nguyên mẫu liên tục, nhưng mạng chưa học được cách tái tạo tốt các mẫu hình đó.

Trong một bước thích ứng (adaptation step) bất kỳ, cửa sổ được lan truyền xuôi (forward-propagation) qua mô hình. Độ lệch tái tạo cửa sổ (window-level reconstruction error) là một hàm khả vi (differentiable) theo tham số ϕ của MLP projector được tính bằng phương trình:

$$S_t^{(\text{hard})}(\phi) = \frac{1}{MTC} \sum_{m=1}^M \left\| \mathbf{X}_t - \hat{\mathbf{X}}_t^{(m)}(\phi) \right\|_F^2. \quad (3.51)$$

Chúng tôi cố gắng kéo điểm tái tạo giảm xuống dưới ngưỡng B_{win} bằng cách sử dụng một *hàm phạt kiểu hinge (hinge-style penalty)*, lấy cảm hứng từ hàm hinge loss trong bài nghiên cứu của tác giả Cortes và tác giả Vapnik từ năm 1995 [53]:

$$\mathcal{L}_{\text{hard-rec}} = \left[S_t^{(\text{hard})}(\phi) - B_{\text{win}} \right]_+, \quad (3.52)$$

trong đó $[x]_+ = \max(0, x)$. Hàm mất mát này sẽ trả về giá trị bằng 0 khi độ lệch tái tạo nhỏ hơn hoặc bằng B_{win} .

Bên cạnh đó, chúng tôi còn sử dụng một *hàm mất mát tương phản* (*contrastive loss*) giữa *nhánh biểu diễn trực tuyến* (*online representation branch*) và *nhánh biểu diễn nguồn* (*source representation branch*). Với mỗi điểm neo là một vec-tơ trực tuyến $\mathbf{z}_{t,i}^{(\text{on})}$, vec-tơ nguồn tương ứng $\mathbf{z}_{t,i}^{(\text{src})}$ được sử dụng làm *điểm dương* (*positives*). Các nguyên mẫu rời rạc thuộc lớp bất thường được sử dụng làm các điểm đối (*negatives*). Gọi

$$\mathcal{K}_{\text{anom}} = \left\{ k \in \{1, \dots, K_d\} : c_k^{(d)} \neq 0 \right\} \quad (3.53)$$

là tập chỉ số của các nguyên mẫu bất thường. Hàm mất mát tương phản được tính bằng

$$\begin{aligned} \mathcal{L}_{\text{src-on}} = & -\frac{1}{T} \sum_{i=1}^T \log \left[\exp \left(\frac{\cos \left(\mathbf{z}_{t,i}^{(\text{on})}, \mathbf{z}_{t,i}^{(\text{src})} \right)}{\tau_{\text{on}}} \right) \right. \\ & \left. \left/ \left(\exp \left(\frac{\cos \left(\mathbf{z}_{t,i}^{(\text{on})}, \mathbf{z}_{t,i}^{(\text{src})} \right)}{\tau_{\text{on}}} \right) \right. \right. \right. \\ & \left. \left. + \sum_{k \in \mathcal{K}_{\text{anom}}} \exp \left(\frac{\cos \left(\mathbf{z}_{t,i}^{(\text{on})}, \mathbf{p}_k^{(d)} \right)}{\tau_{\text{on}}} \right) \right) \right]. \end{aligned} \quad (3.54)$$

Cuối cùng, hàm mất mát cho bước thích ứng (*adaptation step*) đối với cửa sổ *hard-old-normality* là

$$\mathcal{L}_{\text{hard}} = \mathcal{L}_{\text{hard-rec}} + \lambda_{\text{con}} \mathcal{L}_{\text{src-on}}. \quad (3.55)$$

Gradient của hàm số $\mathcal{L}_{\text{hard}}$ chỉ được tính theo ϕ là tham số của mạng MLP projector. Mạng mã hoá, hai bộ nhớ, hai mạng tổng hợp và hai mạng dự đoán đều được giữ cố định trong mọi bước thích ứng xảy ra trên dòng dữ liệu trực tuyến (*online streaming time-series*).

3.3.4 Thích ứng với các mẫu hình giả định bình thường mới đã được xác minh

Các cửa sổ trực tuyến được phân vào luồng *gray zone* chưa thể được xem là có chứa các mẫu hình bình thường mới (new normality) vì các cửa sổ này vẫn có thể chứa các mẫu hình bất thường mà mô hình chưa nhận biết được. Vì vậy, chúng tôi thêm các cửa sổ này vào một *bộ đệm xác minh (verification buffer)* trước khi sử dụng các cửa sổ đó để thích ứng mạng. Các cửa sổ trong bộ đệm xác minh không được chồng lấn nhau (non-overlapping) nhằm đảm bảo rằng sự lặp lại của một mẫu hình không chỉ xuất phát từ việc cùng một điểm thời gian xuất hiện trong nhiều cửa sổ trượt liên tiếp nhau.

Trước hết, chúng tôi sử dụng tập nguyên mẫu rời rạc để loại bỏ các điểm nằm trong một cụm bất thường đã biết ngay sau giai đoạn học biểu diễn đa nhiệm của pha ngoại tuyến. Xét vec-tơ ẩn trực tuyến $\mathbf{z}_{u,i}^{(\text{on})}$, chỉ số của nguyên mẫu rời rạc (discrete codebook) gần với vec-tơ đó nhất trong không gian ẩn là

$$\kappa_{u,i}^{(d)} = \arg \min_{k \in \{1, \dots, K_d\}} \left\| \mathbf{z}_{u,i}^{(\text{on})} - \mathbf{p}_k^{(d)} \right\|_2. \quad (3.56)$$

Gọi $c_k^{(d)} \in \{0, \dots, 11\}$ là nhãn của các lớp bất thường nhân tạo và $r_k^{(d)}$ là bán kính của cụm mẫu hình bất thường tương ứng với nguyên mẫu $\mathbf{p}_k^{(d)}$. Điểm đang xét được chúng tôi xem là có chứa một mẫu hình bất thường đã biết nếu nguyên mẫu rời rạc gần với điểm đó nhất là tâm của một cụm bất thường và điểm đó nằm trong bán kính bao phủ (covering radius) của cụm:

$$M_{u,i}^{(\text{known-anom})} = \mathbb{I} \left[c_{\kappa_{u,i}^{(d)}}^{(d)} \neq 0 \wedge \left\| \mathbf{z}_{u,i}^{(\text{on})} - \mathbf{p}_{\kappa_{u,i}^{(d)}}^{(d)} \right\|_2 \leq r_{\kappa_{u,i}^{(d)}}^{(d)} \right]. \quad (3.57)$$

Các điểm có $M_{u,i}^{(\text{known-anom})} = 1$ bị loại khỏi *bộ đệm xác minh (verification)*

buffer).

Đối với mỗi điểm còn lại, chúng tôi tìm ba nguyên mẫu liên tục (continuous prototype) gần với các điểm đó nhất trong không gian ẩn. Ba chỉ số nguyên mẫu được sắp xếp theo khoảng cách tăng dần để tạo thành một *cấu trúc dữ liệu (data structure)* mà chúng tôi gọi là *chữ ký nguyên mẫu liên tục (continuous prototype signature)*:

$$\sigma_{u,i} = \text{OrderedTopKMin}_{k \in \{1, \dots, K_c\}} \left(\left\| \mathbf{z}_{u,i}^{(\text{on})} - \mathbf{p}_k^{(c)} \right\|_2^2; 3 \right). \quad (3.58)$$

Hai điểm thời gian trực tuyến (online time-point) có cùng *chữ ký (signature)* khi ba nguyên mẫu liên tục gần nhất với hai điểm là giống nhau theo cùng thứ tự. Lúc này, chúng tôi xem như hai vec-tơ ẩn của hai điểm đó nằm trong một khoảng không gian tương tự nhau nếu cùng so với tập nguyên mẫu liên tục.

Tại sao lại là 3 nguyên mẫu liên tục (hay tâm cụm bình thường) gần nhất? Vì chúng tôi hình dung trong không gian 2D như sau: Nếu chọn 1 tâm cụm thì các điểm trên một hình tròn đều gần với cụm đó nhất. Nếu chọn 2 tâm cụm, hình dung khi nối hai tâm cụm thành đường thẳng thì hai điểm nằm ở hai phía của đường thẳng vẫn có thể có khoảng cách bằng nhau đến hai tâm cụm, theo cùng một thứ tự! Nhưng nếu chọn 3 tâm cụm thì chúng tôi sẽ cố định được một vùng trên mặt phẳng 2D thỏa việc khoảng cách của các điểm trong vùng đó đến 3 tâm cụm là có thứ tự như nhau. Chúng tôi kỳ vọng vùng đó cũng có cấu trúc tròn do chúng tôi đã sử dụng thuật toán K-Means trong quá trình khởi tạo các cụm và thuật toán này vốn giả định các cụm trong không gian ẩn hình thành theo cấu trúc tròn. Vậy tại sao không phải 4 cụm, 5 cụm, hay lớn hơn? Đó là vì chúng tôi muốn các chữ ký này có dung lượng nhỏ nhất có thể!

Gọi $\mathcal{B}$ là bộ đệm xác minh (verification buffer). Số cửa sổ khác nhau

trong bộ đệm có chứa chữ ký σ được tính bằng

$$R_{\mathcal{B}}(\sigma) = \sum_{\mathbf{X}_v \in \mathcal{B}} \mathbb{I} \left[\exists j : M_{v,j}^{(\text{known-anom})} = 0 \wedge \sigma_{v,j} = \sigma \right]. \quad (3.59)$$

Một điểm được xác minh là *pseudo-new-normality* nếu nó không khớp với bất kì cụm bất thường đã biết nào và chữ ký của nó xuất hiện trong ít nhất hai cửa sổ không chồng lấn:

$$M_{u,i}^{(\text{pnn})} = \mathbb{I} \left[M_{u,i}^{(\text{known-anom})} = 0 \wedge R_{\mathcal{B}}(\sigma_{u,i}) \geq 2 \right]. \quad (3.60)$$

Lưu ý rằng điều kiện trên đếm số **cửa sổ khác nhau**, không phải đếm số điểm mang cùng chữ ký trong cùng một cửa sổ. Vì vậy, một chữ ký xuất hiện nhiều lần trong cùng một cửa sổ vẫn chưa đủ để được xác minh. Chúng tôi sử dụng từ *pseudo* vì quá trình này không sử dụng nhân thật của chuỗi kiểm thử; “đã được xác minh” chỉ có nghĩa là mẫu hình đã vượt qua phép lọc cụm bất thường và xuất hiện lặp lại trong nhiều cửa sổ độc lập.

Gọi

$$\mathcal{V} = \left\{ (u, i) : M_{u,i}^{(\text{pnn})} = 1 \right\} \quad (3.61)$$

là tập các điểm đã được xác minh. Hàm mất mát tái tạo ở cấp độ điểm (point-level reconstruction loss) chỉ được tính trên những điểm thuộc $\mathcal{V}$:

$$\mathcal{L}_{\text{pnn-rec}} = \frac{1}{M|\mathcal{V}|C} \sum_{m=1}^M \sum_{(u,i) \in \mathcal{V}} \left\| \mathbf{x}_{u,i} - \hat{\mathbf{x}}_{u,i}^{(m)}(\phi) \right\|_2^2. \quad (3.62)$$

Đồng thời, với mỗi điểm neo $\mathbf{z}_{u,i}^{(\text{on})}$, vec-tơ biểu diễn nguồn tương ứng $\mathbf{z}_{u,i}^{(\text{src})}$ được sử dụng làm điểm dương, còn các nguyên mẫu rời rạc thuộc lớp bất thường (các tâm cụm bất thường) được sử dụng làm các điểm

đối. Hàm mất mát tương phản có dạng tường minh là

$$\mathcal{L}_{\text{src-on}}^{(\text{pnn})} = -\frac{1}{|\mathcal{V}|} \sum_{(u,i) \in \mathcal{V}} \log \frac{\exp \left(\cos \left(\mathbf{z}_{u,i}^{(\text{on})}, \mathbf{z}_{u,i}^{(\text{src})} \right) / \tau_{\text{on}} \right)}{\exp \left(\cos \left(\mathbf{z}_{u,i}^{(\text{on})}, \mathbf{z}_{u,i}^{(\text{src})} \right) / \tau_{\text{on}} \right) + \sum_{k \in \mathcal{K}_{\text{anom}}} \exp \left(\cos \left(\mathbf{z}_{u,i}^{(\text{on})}, \mathbf{p}_k^{(d)} \right) / \tau_{\text{on}} \right)}. \quad (3.63)$$

Hàm mất mát của bước thích ứng với các mẫu hình bình thường mới là

$$\mathcal{L}_{\text{pnn}} = \mathcal{L}_{\text{pnn-rec}} + \lambda_{\text{con}} \mathcal{L}_{\text{src-on}}^{(\text{pnn})}. \quad (3.64)$$

Gradient của $\mathcal{L}_{\text{pnn}}$ cũng chỉ được tính theo tham số ϕ của MLP projector. **Nếu** tại cùng một bước thời gian có cả bước thích ứng trên *hard-old-normality* và bước thích ứng trên *verified pseudo-new-normality* **thì** bước thích ứng *hard-old-normality* được thực hiện trước. Đây chỉ đơn giản là một lựa chọn thiết kế của chúng tôi.

Chương 4

Thiết kế thực nghiệm và Kết quả thực nghiệm

4.1 Thiết kế thực nghiệm

Chúng tôi thử nghiệm phương pháp đề xuất trên 3 chuỗi thời gian khác nhau đến từ tập dữ liệu Server Machine Dataset [54] là chuỗi SMD 1-6, chuỗi SMD 3-4 và chuỗi SMD 3-9. Lí do chúng tôi chọn các chuỗi này là vì các chuỗi này có sự thay đổi đủ rõ rệt về mặt phân phối giá trị giữa phần huấn luyện và phần kiểm tra. Kích thước của một cửa sổ đầu vào là 20 và số lượng cửa sổ trong tập huấn luyện, tập xác thực và tập kiểm tra của mỗi chuỗi được trình bày trong bảng bên dưới.

Bảng 4.1: Số lượng cửa sổ với độ dài 20 trong các tập huấn luyện, tập xác thực và tập kiểm tra.

Chuỗi SMD	Huấn luyện	Xác thực	Kiểm tra	Tổng
Machine-1-6	18,932	236	1,184	20,352
Machine-3-4	18,931	236	1,184	20,351
Machine-3-9	22,952	287	1,435	24,674

Đối với pha tiền huấn luyện ngoại tuyến (offline pre-training phase), chúng tôi huấn luyện trên 25 epoch cho giai đoạn học biểu diễn đa nhiệm và 5 epoch cho giai đoạn tinh chỉnh các mạng kết hợp. Tổng số lượng (offline) epoch của phương pháp và các baseline tương ứng sẽ là 30. Một epoch tương đương một lần duyệt hết tập huấn luyện. Trên mỗi chuỗi, chúng tôi thực hiện 3 thí nghiệm với 3 hạt giống ngẫu nhiên (random seed) khác nhau và lấy kết quả trung bình làm kết quả trên chuỗi đó. Cấu hình phần cứng chúng tôi sử dụng là 1 GPU dòng RTX 4070 S với 12GB VRAM và 1 CPU dòng AMD EPYC 7702. Toàn bộ mã nguồn của khóa luận này được chúng tôi lưu trữ tại GitHub repo sau `TheMetaSetter/bachelor-thesis-2026`.

4.2 Kết quả thực nghiệm

Chúng tôi thí nghiệm hai **biến thể (variants)** của pha ngoại tuyến trên các chuỗi SMD 1-6, SMD 3-4 và SMD 3-9. Biến thể THESIS O0 sử dụng các hàm mất mát như đã trình bày ở Mục 3.2. Biến thể THESIS O1 cũng sử dụng các hàm mất mát đó và một hàm mất mát bổ trợ khác tên là *hàm mất mát cân bằng (balanced point-score loss)*. Hàm mất mát cân bằng này sẽ kéo anomaly score của các điểm bình thường xuống thấp hơn anomaly score của các điểm bất thường nhân tạo trong pha tiền huấn luyện ngoại tuyến. Có thể biểu diễn hàm này bằng các phương trình bên dưới.

Trong *chuỗi huấn luyện nhân tạo (synthetic validation series)*, gọi số lượng điểm bình thường là N_0 và số lượng điểm bất thường nhân tạo là N_1 . Mỗi điểm tương ứng một time-step.

$$N_0 = \sum_t \sum_{i=1}^T \mathbb{I}(M_{t,i} = 0), \quad N_1 = \sum_t \sum_{i=1}^T \mathbb{I}(M_{t,i} = 1). \quad (4.1)$$

Trung bình và độ lệch chuẩn trên danh sách anomaly score của các điểm bình thường là:

$$\mu_0 = \frac{1}{N_0} \sum_t \sum_{i=1}^T \mathbb{I}(M_{t,i} = 0) s_{t,i}, \quad (4.2)$$

$$\sigma_0 = \sqrt{\frac{1}{N_0} \sum_t \sum_{i=1}^T \mathbb{I}(M_{t,i} = 0) (s_{t,i} - \mu_0)^2}. \quad (4.3)$$

Chuẩn hóa (normalize) các điểm bất thường (anomaly score) trước khi tính giá trị hàm mất mát cân bằng.

$$\eta_{t,i} = \frac{s_{t,i} - \mu_0}{\max(\sigma_0, \varepsilon)}. \quad (4.4)$$

Giá trị của hàm mất mát cân bằng được tính toán bằng phương trình:

$$\mathcal{L}_{\text{BPSL}} = -\frac{1}{2N_0} \sum_t \sum_{i=1}^T \mathbb{I}(M_{t,i} = 0) \log [\text{sigmoid}(-\eta_{t,i})] - \frac{1}{2N_1} \sum_t \sum_{i=1}^T \mathbb{I}(M_{t,i} = 1) \log [\text{sigmoid}(\eta_{t,i})]. \quad (4.5)$$

Bảng 4.2: So sánh hiệu quả pha ngoại tuyến của phương pháp đề xuất với các phương pháp đối sánh.

	machine-1-6			machine-3-4			machine-3-9			Average		
	VUS-PR	Aff. F1	VUS-ROC	VUS-PR	Aff. F1	VUS-ROC	VUS-PR	Aff. F1	VUS-ROC	VUS-PR	Aff. F1	VUS-ROC
THESIS O0	<u>0.798</u>	<u>0.747</u>	0.892	0.705	<u>0.708</u>	0.950	<u>0.578</u>	0.789	<u>0.645</u>	0.694	<u>0.748</u>	<u>0.829</u>
THESIS O1	0.799	0.748	<u>0.892</u>	<u>0.705</u>	0.708	<u>0.950</u>	<u>0.578</u>	<u>0.793</u>	<u>0.645</u>	0.694	0.749	<u>0.829</u>
RedLamp	0.586	0.701	0.500	0.614	0.708	0.890	0.518	0.824	0.547	0.573	0.744	0.646
iForest	0.265	0.434	0.623	0.154	0.151	0.830	0.028	0.645	0.249	0.149	0.410	0.568
KMeans-AD	0.300	0.300	0.766	0.392	0.136	0.949	0.675	0.699	0.900	0.455	0.379	0.872
StumPy	0.175	0.190	0.499	0.058	0.624	0.506	0.045	0.592	0.550	0.093	0.469	0.518

Kết quả thí nghiệm của pha tiền huấn luyện ngoại tuyến cho thấy cả hai biến thể của phương pháp đề xuất (THESIS) đều tốt hơn các phương pháp đối sánh trên 2 độ đo VUS-PR và Affiliation F1-score, đặc biệt là phương pháp RedLamp [7]. Chúng tôi xét phương pháp RedLamp như một biến thể của THESIS nhưng bị cắt bỏ hai mô-đun bộ nhớ. Do biến thể THESIS O1 **không** tốt hơn đáng kể (significantly better than) biến thể THESIS O0 nên chúng tôi nhận định rằng việc sử dụng hai mô-đun bộ nhớ đóng góp vào mức tăng trên các độ đo nhiều hơn việc sử dụng hàm mất mát cân bằng.

Bảng 4.3: Quan sát độ bất định của mạng nơ-ron trong pha ngoại tuyến.

	machine-1-6				machine-3-4				machine-3-9			
	VUS-PR	Aff. F1	Validation	Test	VUS-PR	Aff. F1	Validation	Test	VUS-PR	Aff. F1	Validation	Test
THESIS O0	0.798	0.747	0.012	0.250	0.705	0.708	0.013	0.432	0.578	0.789	0.013	0.045
THESIS O1	0.799	0.748	0.006	0.089	0.704	0.708	0.019	0.573	0.578	0.793	0.024	0.061
Average												
	VUS-PR	Aff. F1	Validation	Test								
THESIS O0	0.694	0.748	0.013	0.242								
THESIS O1	0.694	0.749	0.016	0.241								

Kết quả thí nghiệm cho thấy độ bất định của mạng nơ-ron trên *tập xác thực (validation set)* thấp hơn so với độ bất định của mạng nơ-ron trên *tập kiểm tra (test set)*. Ngoài ra, các độ đo trên tập kiểm tra vẫn cho thấy kết quả tốt dù độ bất định cao hơn, phần nào cho thấy mô hình có khả năng *tổng quát hoá (generalization)* trên tập kiểm tra mà không gặp phải *hiện tượng tự tin quá mức (overconfidence)*. Đây chính là hành vi mà chúng tôi kỳ vọng phương pháp ước lượng độ bất định có được.

Bảng 4.4: Kết quả cuối cùng ở pha online của THESIS, M2N2 và CANDI.

	machine-1-6			machine-3-4			machine-3-9			Average		
	VUS-PR	Aff. F1	VUS-ROC	VUS-PR	Aff. F1	VUS-ROC	VUS-PR	Aff. F1	VUS-ROC	VUS-PR	Aff. F1	VUS-ROC
THESIS O0 + A0	<u>0.808</u>	<u>0.999</u>	0.895	0.980	0.721	0.978	0.659	0.765	0.730	0.816	<u>0.828</u>	0.868
THESIS O0 + A1	<u>0.808</u>	<u>0.999</u>	0.895	0.980	0.721	0.978	0.659	0.765	0.730	0.816	<u>0.828</u>	0.868
THESIS O0 + A2	<u>0.808</u>	<u>0.999</u>	0.895	0.980	0.721	0.978	0.657	0.765	0.728	0.815	<u>0.828</u>	0.867
THESIS O1 + A0	0.824	0.999	<u>0.898</u>	0.980	0.721	0.977	0.667	<u>0.818</u>	<u>0.734</u>	0.824	0.846	0.869
THESIS O1 + A1	0.824	0.999	<u>0.898</u>	0.980	0.721	0.977	0.667	<u>0.818</u>	<u>0.734</u>	0.824	0.846	0.869
THESIS O1 + A2	0.824	0.999	<u>0.898</u>	<u>0.980</u>	0.721	0.977	<u>0.666</u>	<u>0.818</u>	0.734	<u>0.824</u>	0.846	0.869
M2N2	0.574	0.791	0.983	0.815	0.721	<u>0.976</u>	0.717	0.997	<u>0.857</u>	0.702	<u>0.836</u>	0.939
CANDI	<u>0.590</u>	<u>0.793</u>	<u>0.973</u>	<u>0.919</u>	0.721	0.962	0.608	0.808	0.871	<u>0.706</u>	0.774	<u>0.935</u>

Chúng tôi thiết kế thí nghiệm pha trực tuyến với ba biến thể của phương pháp thích ứng là A0, A1 và A2. Biến thể A0 là hoàn toàn không thích ứng. Biến thể A1 có thích ứng nhưng không sử dụng hàm mất mát tương phản (contrastive loss) (xem Phương trình (3.54)) giữa nhánh biểu diễn trực tuyến và nhánh biểu diễn nguồn. Biến thể A2 có thích ứng và sử dụng tất cả hàm mất mát trong phương pháp đề xuất, bao gồm một hàm phạt kiểu hinge (xem Phương trình (3.52)) và một hàm mất mát tương phản.

Kết quả thí nghiệm cho thấy các biến thể sử dụng thích ứng trực tuyến (trong Bảng 4.4) *đều có kết quả độ đo cao hơn so với các biến thể thuần tiền huấn luyện ngoại tuyến (trong Bảng 4.2) và cao hơn hai phương pháp đối sánh chính là M2N2 [32] và [33].* Tuy nhiên, khi cố định biến thể ngoại tuyến và sử dụng các biến thể trực tuyến khác nhau, kết quả độ đo không thay đổi đáng kể, kể cả đối với biến thể không sử dụng thích ứng. Điều này cho thấy, thay đổi của pha trực tuyến (so với pha ngoại tuyến) đóng góp chính vào mức tăng của các độ đo chính là việc sử dụng kỹ thuật làm trơn (smoothing) chuỗi điểm bất thường bằng phép tính trung bình trượt hàm mũ (*exponentially weighted moving average – EWMA*). Thay đổi đơn giản nhất này đóng góp nhiều nhất vào mức tăng.

Chương 5

Kết luận và hướng nghiên cứu tương lai

Trong báo cáo này, chúng tôi đã đề xuất hai mô-đun toán tử truy vấn liên tục và rời rạc, cùng phiên bản ngẫu nhiên tương ứng với từng toán tử phục vụ việc định lượng độ bất định. Ngoài ra, chúng tôi đề xuất một phương pháp thích ứng khi kiểm thử sử dụng cơ chế phân luồng và hàm mất mát tương phản giữa nhánh biểu diễn trực tuyến và ngoại tuyến. Kết quả thực nghiệm cho thấy pha ngoại tuyến và pha trực tuyến của phương pháp đều tốt hơn so với các phương pháp đối sánh được chúng tôi lựa chọn. Trong pha trực tuyến, việc sử dụng cơ chế làm trơn đóng góp nhiều nhất vào mức tăng hiệu quả. Kết quả định lượng bất định cũng cho thấy mạng có độ bất định cao hơn khi tính toán trên tập kiểm tra và các độ đo vẫn cho thấy mạng tổng quát hoá tốt trên dữ liệu chưa được học khi huấn luyện. Cuối cùng, chúng tôi xin đề xuất hai hướng nghiên cứu tương lai như sau: 1. Giảm *tỉ lệ báo động giả* (*false positive rate*) để đẩy lùi thực trạng *mệt mỏi vì báo động* (*alarm fatigue*) trong một số lĩnh vực như giám sát hệ thống phần mềm và đám mây, hay trong các đơn vị hồi sức tích cực, và 2. Nghiên cứu cách đánh giá chất lượng ước lượng độ bất định để có cơ sở so sánh công bằng các phương pháp ước lượng độ bất định khác nhau trong bài toán phát hiện bất thường chuỗi thời gian đa biến.

Tài liệu tham khảo

Tiếng Anh

- [1] Chen, F. et al., “Cluster-wide task slowdown detection in cloud system,” in *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, ser. KDD '24, New York, NY, USA: Association for Computing Machinery, 2024, pp. 266–277. DOI: 10.1145/3637528.3671936. [Online]. Available: <https://doi.org/10.1145/3637528.3671936>.
- [2] Lehman, L.-w. et al., “Vtac: A benchmark dataset of ventricular tachycardia alarms from icu monitors,” in *Advances in Neural Information Processing Systems*, Oh, A., Naumann, T., Globerson, A., Saenko, K., Hardt, M., and Levine, S., Eds., vol. 36, Curran Associates, Inc., 2023, pp. 38 827–38 843. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2023/file/7a53bf4e02022aad32a4019d41b3b476-Paper-Datasets_and_Benchmarks.pdf.
- [3] Gabrielli, D., Prenkaj, B., Velardi, P., and Faralli, S., “Ai on the pulse: Real-time health anomaly detection with wearable and ambient intelligence,” in *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*, ser. CIKM '25, New York, NY, USA: Association for Computing Machinery, 2025, pp. 4717–4721. DOI: 10.1145/3746252.3760799. [Online]. Available: <https://doi.org/10.1145/3746252.3760799>.

- [4] Kim, S., Hwang, J., and Park, S., “Step-aware cross-view transformer for unsupervised semiconductor manufacturing equipment anomaly detection,” *IEEE Internet of Things Journal*, vol. 13, no. 12, pp. 26 470–26 482, 2026. DOI: 10.1109/JIOT.2026.3677542.
- [5] Deka, P. K., Verma, Y., Bhutto, A. B., Elmroth, E., and Bhuyan, M., “Semi-supervised range-based anomaly detection for cloud systems,” *IEEE Transactions on Network and Service Management*, vol. 20, no. 2, pp. 1290–1304, 2023. DOI: 10.1109/TNSM.2022.322 5753.
- [6] Islam, M. S., Rakha, M. S., Pourmajidi, W., Sivaloganathan, J., Steinbacher, J., and Miransky, A., “Anomaly detection in large-scale cloud systems: An industry case and dataset,” in *2025 IEEE/ACM 47th International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, 2025, pp. 377–388. DOI: 10.1109/ICSE-SEIP66354.2025.00039.
- [7] Obata, K., Matsubara, Y., and Sakurai, Y., “Robust and explainable detector of time series anomaly via augmenting multiclass pseudo-anomalies,” in *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2*, ser. KDD ’25, New York, NY, USA: Association for Computing Machinery, 2025, pp. 2198–2209. DOI: 10.1145 / 3711896.3737110. [Online]. Available: <https://doi.org/10.1145/3711896.3737110>.
- [8] Jeong, J. and Yoon, H., “PGRF-net: A prototype-guided relational fusion network for diagnostic multivariate time-series anomaly detection,” in *The Fourteenth International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=3hS7EtL4bV>.
- [9] Darban, Z. Z., Webb, G. I., Pan, S., Aggarwal, C. C., and Salehi, M., “CARLA: Self-supervised contrastive representation learning for time series anomaly detection,” *Pattern Recognition*, vol. 157,

- p. 110 874, 2025, ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110874>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0031320324006253>.
- [10] Jang, E., Gu, S., and Poole, B., “Categorical reparameterization with gumbel-softmax,” in *International Conference on Learning Representations*, 2017. [Online]. Available: <https://openreview.net/forum?id=rkE3y85ee>.
 - [11] Wei, Q. et al., “Evolving proxy kills drift: Data-efficient streaming time series anomaly detection,” in *Proceedings of the ACM Web Conference 2026*, Association for Computing Machinery, 2026, pp. 7295–7306. DOI: 10.1145/3774904.3792440. [Online]. Available: <https://doi.org/10.1145/3774904.3792440>.
 - [12] Rajan, V. M. and Bhadra, S., “HEIGHTS: Hierarchical graph structure learning for time series anomaly detection,” *Neurocomputing*, vol. 671, p. 132 638, 2026. DOI: 10.1016/j.neucom.2026.132 638. [Online]. Available: <https://doi.org/10.1016/j.neucom.2026.132638>.
 - [13] Wu, Z., Zhang, Q., Zhou, J., Chen, H., and Liu, Y., “WAVAE: A weakly augmented variational autoencoder for time series anomaly detection,” *Information Fusion*, vol. 125, p. 103 462, 2026. DOI: 10.1016/j.inffus.2025.103462. [Online]. Available: <https://doi.org/10.1016/j.inffus.2025.103462>.
 - [14] Martinez, N., O’Donncha, F., Gifford, W. M., Zhou, N., Patel, D. C., and Vaculin, R., “Adaptive conformal anomaly detection with time series foundation models for signal monitoring,” in *The Fourteenth International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=7uFbs68MSI>.

- [15] Banerjee, A. and Gupta, S., “Detection of unknown unknowns in autonomous systems,” in *The Fourteenth International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=GrsofC2FqF>.
- [16] Shen, L., Peng, L., Liu, R., Xia, S., and Liu, Y., “Finding time series anomalies using granular-ball vector data description,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 40, no. 30, 2026. DOI: 10.1609/aaai.v40i30.39722. [Online]. Available: <https://doi.org/10.1609/aaai.v40i30.39722>.
- [17] Jeong, J. and Yoon, H., “PGRF-Net: A prototype-guided relational fusion network for diagnostic multivariate time-series anomaly detection,” in *The Fourteenth International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=3hS7EtL4bV>.
- [18] Park, J. and Kang, S., “PaAno: Patch-based representation learning for time-series anomaly detection,” in *The Fourteenth International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=NXThkM7Iym>.
- [19] Zhuang, Z. et al., “Noise matters: Cross contrastive learning for flink anomaly detection,” *Proceedings of the VLDB Endowment*, vol. 18, no. 4, pp. 1159–1168, 2024. DOI: 10.14778/3717755.3717773. [Online]. Available: <https://doi.org/10.14778/3717755.3717773>.
- [20] Kim, S., Hwang, J., and Park, S., “Step-aware cross-view transformer for unsupervised semiconductor manufacturing equipment anomaly detection,” *IEEE Internet of Things Journal*, vol. 13, no. 12, pp. 26 470–26 482, 2026. DOI: 10.1109/JIOT.2026.3677542. [Online]. Available: <https://doi.org/10.1109/JIOT.2026.3677542>.
- [21] Li, Q., Liu, Y., Chen, B., Yuan, Z., Peng, D., and Wang, S., “Natural granular-ball anomaly detection,” *Applied Soft Computing*,

- vol. 197, p. 115–147, 2026. DOI: 10.1016/j.asoc.2026.115147. [Online]. Available: <https://doi.org/10.1016/j.asoc.2026.115147>.
- [22] Zamanzadeh Darban, Z., Webb, G. I., Pan, S., Aggarwal, C., and Salehi, M., “Deep learning for time series anomaly detection: A survey,” *ACM Comput. Surv.*, vol. 57, no. 1, Oct. 2024, ISSN: 0360-0300. DOI: 10.1145/3691338. [Online]. Available: <https://doi.org/10.1145/3691338>.
- [23] Zhuang, Z. et al., “Noise matters: Cross contrastive learning for flink anomaly detection,” *Proceedings of the VLDB Endowment*, vol. 18, no. 4, pp. 1159–1168, 2024. DOI: 10.14778/3717755.3717773. [Online]. Available: <https://doi.org/10.14778/3717755.3717773>.
- [24] Nam, Y. et al., “Breaking the time-frequency granularity discrepancy in time-series anomaly detection,” in *Proceedings of the ACM Web Conference 2024*, Association for Computing Machinery, 2024, pp. 4204–4215. DOI: 10.1145/3589334.3645556. [Online]. Available: <https://doi.org/10.1145/3589334.3645556>.
- [25] Wu, X. et al., “CATCH: Channel-aware multivariate time series anomaly detection via frequency patching,” in *The Thirteenth International Conference on Learning Representations*, 2025. [Online]. Available: <https://openreview.net/forum?id=m08aK3xxdJ>.
- [26] Shentu, Q. et al., “Towards a general time series anomaly detector with adaptive bottlenecks and dual adversarial decoders,” in *The Thirteenth International Conference on Learning Representations*, 2025. [Online]. Available: <https://openreview.net/forum?id=aKcd7ImG5e>.
- [27] Gil, N. M., O’Donncha, F., Gifford, W. M., Zhou, N., Patel, D. C., and Vaculin, R., “Adaptive conformal anomaly detection with time series foundation models for signal monitoring,” in *The Fourteenth*

- International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=7uFbs68MSI>.
- [28] Hu, S., Jin, J., Shu, Y., Chen, P., Yang, B., and Guo, C., “Towards multimodal time series anomaly detection with semantic alignment and condensed interaction,” in *The Fourteenth International Conference on Learning Representations*, 2026. [Online]. Available: <https://openreview.net/forum?id=fNFbGqu6Rg>.
 - [29] He, Z., Alnegheimish, S., and Reimherr, M., “Harnessing vision-language models for time series anomaly detection,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 40, no. 26, pp. 21 690–21 698, 2026. DOI: 10.1609/aaai.v40i26.39319. [Online]. Available: <https://doi.org/10.1609/aaai.v40i26.39319>.
 - [30] Song, J., Kim, K., Oh, J., and Cho, S., “Memto: Memory-guided transformer for multivariate time series anomaly detection,” in *Proceedings of the 37th International Conference on Neural Information Processing Systems*, ser. NIPS ’23, Red Hook, NY, USA: Curran Associates Inc., 2023.
 - [31] Li, C.-G., “Learn hybrid prototypes for multivariate time series anomaly detection,” in *The Thirteenth International Conference on Learning Representations*, 2025. [Online]. Available: <https://openreview.net/forum?id=8TBGdH3t6a>.
 - [32] Kim, D., Park, S., and Choo, J., “When model meets new normals: Test-time adaptation for unsupervised time-series anomaly detection,” vol. 38, pp. 13 113–13 121, Mar. 2024. DOI: 10.1609/aaai.v38i12.29210. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/29210>.
 - [33] Kim, H., Mok, J., Lee, H., Shin, J., and Yoon, S., “Candi: Curated test-time adaptation for multivariate time-series anomaly detection under distribution shift,” *Proceedings of the AAAI Confer-*

- ence on Artificial Intelligence*, vol. 40, no. 17, pp. 15 018–15 026, Mar. 2026. DOI: 10.1609/aaai.v40i17.38524. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/38524>.
- [34] Kendall, A. and Gal, Y., “What uncertainties do we need in bayesian deep learning for computer vision?” In *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17, Long Beach, California, USA: Curran Associates Inc., 2017, pp. 5580–5590, ISBN: 9781510860964.
 - [35] Deng, D., Chen, G., Yu, Y., Liu, F., and Heng, P.-A., “Uncertainty estimation by fisher information-based evidential deep learning,” in *Proceedings of the 40th International Conference on Machine Learning*, ser. ICML’23, Honolulu, Hawaii, USA: JMLR.org, 2023.
 - [36] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R., “Dropout: A simple way to prevent neural networks from overfitting,” *J. Mach. Learn. Res.*, vol. 15, no. 1, pp. 1929–1958, Jan. 2014, ISSN: 1532-4435.
 - [37] Gal, Y. and Ghahramani, Z., “Dropout as a bayesian approximation: Representing model uncertainty in deep learning,” in *Proceedings of The 33rd International Conference on Machine Learning*, Balcan, M. F. and Weinberger, K. Q., Eds., ser. Proceedings of Machine Learning Research, vol. 48, New York, New York, USA: PMLR, 20–22 Jun 2016, pp. 1050–1059. [Online]. Available: <https://proceedings.mlr.press/v48/gal16.html>.
 - [38] Lakshminarayanan, B., Pritzel, A., and Blundell, C., “Simple and scalable predictive uncertainty estimation using deep ensembles,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17, Long Beach, California, USA: Curran Associates Inc., 2017, pp. 6405–6416, ISBN: 9781510860964.

- [39] Bahdanau, D., Cho, K., and Bengio, Y., “Neural machine translation by jointly learning to align and translate,” in *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, Bengio, Y. and LeCun, Y., Eds., 2015.
- [40] Pei, J., Wang, C., and Szarvas, G., “Transformer uncertainty estimation with hierarchical stochastic attention,” 2022. [Online]. Available: <https://www.amazon.science/publications/transformer-uncertainty-estimation-with-hierarchical-stochastic-attention>.
- [41] Boniol, P., Krishna, A. K., Bruel, M., and Palpanas, T., “VUS: Effective and efficient accuracy measures for time-series anomaly detection,” *The VLDB Journal*, vol. 34, no. 32, 2025. DOI: 10.1007/s00778-025-00907-x. [Online]. Available: <https://doi.org/10.1007/s00778-025-00907-x>.
- [42] Huet, A., Navarro, J. M., and Rossi, D., “Local evaluation of time series anomaly detection algorithms,” in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, ser. KDD ’22, Washington DC, USA: Association for Computing Machinery, 2022, pp. 635–645, ISBN: 9781450393850. DOI: 10.1145/3534678.3539339. [Online]. Available: <https://doi.org/10.1145/3534678.3539339>.
- [43] Oord, A. van den, Vinyals, O., and Kavukcuoglu, K., “Neural discrete representation learning,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17, Long Beach, California, USA: Curran Associates Inc., 2017, pp. 6309–6318, ISBN: 9781510860964.
- [44] Zhou, K., Liu, Z., Qiao, Y., Xiang, T., and Loy, C. C., “Domain Generalization: A Survey,” *IEEE Transactions on Pattern Analysis & Machine Intelligence*, vol. 45, no. 04, pp. 4396–4415, Apr. 2023, ISSN: 1939-3539. DOI: 10.1109/TPAMI.2022.3195549. [Online].

Available: <https://doi.ieeecomputersociety.org/10.1109/TPAMI.2022.3195549>.

- [45] Wang, T. and Isola, P., “Understanding contrastive representation learning through alignment and uniformity on the hypersphere,” in *Proceedings of the 37th International Conference on Machine Learning*, ser. ICML’20, JMLR.org, 2020.
- [46] Lloyd, S. P., “Least squares quantization in pcm,” *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982. DOI: 10.1109/TIT.1982.1056489.
- [47] Vaswani, A. et al., “Attention is all you need,” in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, ser. NIPS’17, Long Beach, California, USA: Curran Associates Inc., 2017, pp. 6000–6010, ISBN: 9781510860964.
- [48] Lin, H., Cheng, X., Wu, X., and Shen, D., “Cat: Cross attention in vision transformer,” in *2022 IEEE International Conference on Multimedia and Expo (ICME)*, 2022, pp. 1–6. DOI: 10.1109/ICME52920.2022.9859720.
- [49] Rumelhart, D. E., Hinton, G. E., and Williams, R. J., “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986. DOI: 10.1038/323533a0. [Online]. Available: <https://www.nature.com/articles/323533a0>.
- [50] Sinha, N. K. and Griscik, M. P., “A stochastic approximation method,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-1, no. 4, pp. 338–344, 1971. DOI: 10.1109/TSMC.1971.4308316.
- [51] Kingma, D. P. and Ba, J., “Adam: A method for stochastic optimization,” in *Proceedings of the International Conference on Learning Representations*, 2015.

- [52] Loshchilov, I. and Hutter, F., “Decoupled weight decay regularization,” in *International Conference on Learning Representations*, 2019. [Online]. Available: <https://openreview.net/forum?id=Bkg6RiCqY7>.
- [53] Cortes, C. and Vapnik, V., “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995. DOI: 10.1007/BF00994018.
- [54] Su, Y., Zhao, Y., Niu, C., Liu, R., Sun, W., and Pei, D., “Robust anomaly detection for multivariate time series through stochastic recurrent neural network,” in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, ser. KDD ’19, New York, NY, USA: Association for Computing Machinery, 2019, pp. 2828–2837. DOI: 10.1145/3292500.3330672. [Online]. Available: <https://doi.org/10.1145/3292500.3330672>.